

**ANALISIS SENTIMEN PENGGUNA APLIKASI GRAB DAN
GOJEK MENGGUNAKAN METODE SUPPORT VECTOR
MACHINE (SVM)**

SKIRPSI

Sebagai Salah Satu Syarat Untuk Memperoleh Gelar Sarjana Komputer



Oleh :

TEGAR BIMO PRAKOSO PUTRA NGABEI (BEI)

11200910000028

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS ISLAM NEGERI SYARIF HIDAYATULLAH

JAKARTA

2026 M / 1447 H

LEMBAR PERSETUJUAN

ANALISIS SENTIMEN PENGGUNA APLIKASI GRAB DAN GOJEK MENGUNAKAN METODE SUPPORT VECTOR MACHINE (SVM)

Skripsi

Sebagai Salah Satu Syarat untuk Memperoleh Gelar

Sarjana Komputer (S.Kom)

Oleh

Tegar Bimo Prakosso Putra Ngabei (Bei)


Menyetujui,

Pembimbing 1



Anif Hanifa Setianingrum M.Si
NIP. 196410102024212001

Pembimbing 2



Fitri Mintarsih M.Kom.
NIP. 197212232007102004

PERNYATAAN ORISINALITAS

Dengan ini saya menyatakan bahwa:

1. Skripsi ini merupakan hasil karya asli saya yang diajukan untuk memenuhi salah satu persyaratan memperoleh gelar Strata 1 (S1) di UIN Syarif Hidayatullah Jakarta.
2. Semua sumber yang saya gunakan dalam penulisan ini telah saya cantumkan sesuai dengan ketentuan yang berlaku di UIN Syarif Hidayatullah Jakarta.
3. Jika di kemudian hari terbukti bahwa karya ini bukan hasil karya asli saya atau merupakan hasil jiplakan dari karya orang lain, maka saya bersedia menerima sanksi yang berlaku di UIN Syarif Hidayatullah Jakarta.

Jakarta, 10 Maret 2026



Tegar Bimo Prakoso Putra Ngabei (Bei)

NIM. 11200910000028

Nama : Tegar Bimo Prakoso Putra Ngabei (Bei)
Program Studi : Teknik Informatika
Judul : ANALISIS SENTIMEN PENGGUNA APLIKASI GRAB
DAN GOJEK MENGGUNAKAN METODE SUPPORT
VECTOR MACHINE (SVM)

ABSTRAK

Penelitian ini bertujuan untuk menganalisis sentimen pengguna terhadap aplikasi Grab dan Gojek menggunakan algoritma *Support Vector Machine* (SVM). Data berupa 3.990 ulasan pengguna dari *Google Play Store* (masing-masing 1.995 ulasan Grab dan Gojek) diklasifikasikan ke dalam tiga kategori sentimen: positif, negatif, dan netral. Tahapan pengolahan data meliputi *preprocessing* teks (*case folding, tokenizing, stopword removal, dan stemming*) serta ekstraksi fitur menggunakan *Term Frequency-Inverse Document Frequency* (TF-IDF) sebelum diklasifikasikan dengan SVM pendekatan *LinearSVC*. Latar belakang empiris penulis sebagai pengemudi digunakan sebagai observasi awal tanpa menjadikan pengemudi sebagai objek penelitian. Hasil penelitian menunjukkan model SVM mencapai akurasi **91% pada dataset Grab** dan **96% pada dataset Gojek**. Evaluasi menggunakan *confusion matrix, precision, recall, dan *F1-score** mengonfirmasi bahwa algoritma SVM memiliki kinerja sangat baik dan efektif digunakan dalam analisis sentimen ulasan pengguna aplikasi transportasi *online* berbasis teks.

Kata Kunci: Analisis Sentimen, *Support Vector Machine*, SVM, Grab, Gojek, Google Play Store, TF-IDF, Klasifikasi Teks.

Name : Tegar Bimo Prakoso Putra Ngabei (Bei)
Program Studi : Teknik Informatika
Title : SENTIMENT ANALYSIS OF GRAB AND GOJEK
APPLICATION USERS USING THE SUPPORT VECTOR
MACHINE (SVM) METHOD

ABSTRACT

*This study aims to analyze user sentiment toward the Grab and Gojek applications using the Support Vector Machine (SVM) algorithm. A total of 3,990 user reviews from the Google Play Store (1,995 reviews for each application) were classified into three sentiment categories: positive, negative, and neutral. The data processing stages included text preprocessing (case folding, tokenizing, stopword removal, and stemming) and feature extraction using Term Frequency-Inverse Document Frequency (TF-IDF) before classification with the LinearSVC approach. The author's empirical background as a driver served as initial observation without positioning drivers as research objects. The results showed that the SVM model achieved accuracies of **91% on the Grab dataset** and **96% on the Gojek dataset**. Evaluation using confusion matrix, precision, recall, and F1-score confirmed that the SVM algorithm performs excellently and is effective for text-based sentiment analysis of online transportation application user reviews.*

Keywords: Sentiment Analysis, Support Vector Machine, SVM, Grab, Gojek, Google Play Store, TF-IDF, Text Classification.

KATA PENGANTAR

Assalamu 'alaikum Warahmatullahi Wabarakatuh.

Puji dan syukur penulis panjatkan ke hadirat Allah SWT atas limpahan nikmat iman, nikmat Islam, serta nikmat kesehatan yang telah diberikan, sehingga penulis dapat menyelesaikan penyusunan skripsi ini dengan baik. Shalawat serta salam senantiasa tercurah kepada junjungan kita Nabi Besar Muhammad Shallallahu 'Alaihi Wassalam, suri teladan umat manusia, yang telah membawa umat dari masa kegelapan menuju masa yang penuh cahaya ilmu pengetahuan sebagaimana yang dirasakan pada masa kini.

Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer (S.Kom) pada Program Studi Teknik Informatika, Fakultas Sains dan Teknologi, Universitas Islam Negeri Syarif Hidayatullah Jakarta. Penulis menyadari bahwa proses penyusunan skripsi ini tidak selalu berjalan dengan mudah. Terdapat berbagai keterbatasan dan ujian yang harus dihadapi, termasuk kondisi kesehatan penulis pada masa perkuliahan dan penyusunan tugas akhir. Namun, atas izin Allah SWT serta dukungan dan perhatian dari pihak-pihak terdekat, penulis dapat melalui proses tersebut hingga skripsi ini dapat diselesaikan.

Pada kesempatan ini, penulis menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Allah SWT, yang senantiasa melimpahkan rahmat, nikmat, dan karunia-Nya, serta memberikan kekuatan dan kemudahan kepada penulis dalam setiap tahapan penyusunan skripsi ini.
2. Ibu Dr. Dewi Khairani, M.Sc., selaku Ketua Program Studi Teknik Informatika, beserta seluruh jajaran staf dan dosen Program Studi Teknik Informatika yang telah memberikan ilmu pengetahuan, wawasan, dan pengalaman berharga kepada penulis selama menempuh pendidikan.
3. Ibu Anif Hanifa Setianingrum, M.Si., selaku Dosen Pembimbing I, dan Ibu Fitri Mintarsih, M.Kom., selaku Dosen Pembimbing II, yang telah dengan penuh kesabaran memberikan bimbingan, arahan, masukan, serta motivasi yang sangat berarti kepada penulis selama proses penyusunan skripsi, terutama dalam memastikan ketepatan penerapan metode dan alur penelitian sehingga skripsi ini dapat terselesaikan dengan baik.
4. Ibu Khodijah Hulliyah, M.Si., Ph.D. selaku Dosen Penguji I dan Bapak Victor Amrizal, M.Kom. selaku Dosen Penguji II, atas segala ilmu, kritik

membangun, serta arahan yang telah diberikan dalam proses pengujian demi kesempurnaan laporan tugas akhir ini.

5. Ibu Rochayati, S.E., M.B.A., selaku ibu penulis, yang senantiasa hadir memberikan doa, perhatian, dan pengorbanan tanpa henti. Ketulusan, kepedulian, serta kesigapan Ibu dalam mendampingi dan menjaga penulis, khususnya pada masa-masa sulit ketika penulis berada dalam kondisi yang kurang baik, menjadi sumber kekuatan utama yang memungkinkan penulis untuk bangkit dan menyelesaikan pendidikan ini.
6. Doni Febrian, Daffa A'sha Alifa, Dimas Restu Aetna, Muhammad Zhafran Athofani, Khair Fadhillah, Muhamad Fardal Akter Min Gali, Muhammad Fadlie Putra Pratama, Reza Febryan Saputra, Muhammad Raihan Albairuny, Rio Rizky Alfriansyah, Raihan Revaldy Azura, Muhamad Zulfan Taqiyudin Baehaqi, dan Yahya Pratama yang telah berbagi pengetahuan, memberikan inspirasi dan masukan, memberikan semangat dalam menyelesaikan tugas akhir skripsi ini, serta telah dan semoga selalu menemani selama dan setelah masa studi di UIN Syarif Hidayatullah Jakarta.
7. Seluruh pihak yang tidak dapat penulis sebutkan satu per satu, yang telah memberikan bantuan dan dukungan baik secara langsung maupun tidak langsung dalam penyelesaian skripsi ini.

Sebagai penutup, penulis berharap semoga skripsi ini dapat memberikan manfaat serta menambah wawasan dan pengetahuan, baik bagi penulis pribadi maupun bagi para pembaca. Penulis menyadari bahwa skripsi ini masih jauh dari kesempurnaan, karena sesungguhnya kesempurnaan hanyalah milik Allah SWT. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun demi perbaikan di masa yang akan datang.

Wassalamu 'alaikum Warahmatullahi Wabarakatuh.

DAFTAR ISI

LEMBAR PERSETUJUAN.....	ii
PERNYATAAN ORISINALITAS.....	iii
ABSTRAK	IV
ABSTRACT	V
KATA PENGANTAR.....	VI
DAFTAR ISI	VIII
DAFTAR GAMBAR	X
DAFTAR TABEL.....	XI
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Identifikasi Masalah	3
1.3 Rumusan Masalah	4
1.4 Batasan Masalah.....	4
1.5 Tujuan Penelitian.....	5
1.6 Manfaat Penelitian	5
1.7 Ruang Lingkup Penelitian.....	5
1.8 Sistematika Penulisan	6
BAB II LANDASAN TEORI	7
2.1 Analisis Sentimen.....	7
2.2 Text Mining	10
2.3 Preprocessing Data Teks	12
2.4 Google Play Store sebagai Sumber Data	13
2.5 CRISP-DM.....	14
2.6 Support Vector Machine (SVM)	16
2.6.1 Linear SVM dan Optimal Hyperplane	18
2.6.2 Non-Linear SVM dan Kernel Trick	19
2.7 TF-IDF (Term Frequency-Inverse Document Frequency).....	25
2.8 Confusion Matrix	29

2.9 Gojek.....	31
2.10 Grab.....	32
2.11 Perangkat Pengembangan (<i>Development Tools</i>)	33
2.11.1 Bahasa Pemrograman Python.....	33
2.11.2 Google Colaboratory	35
2.12 Studi Literatur	36
BAB III METODE PENELITIAN.....	39
3.1 Kerangka Berpikir.....	39
3.2 Metode Pengumpulan Data	42
3.3 Metode Implementasi Eksperimen.....	45
3.4 Alur Penelitian.....	47
BAB IV IMPLEMENTASI.....	50
4.1 Business Understanding	50
4.2 Data Understanding.....	51
4.3 Data Preparation.....	56
4.4 Modeling (Implementasi SVM).....	62
4.5 Evaluasi Model.....	65
BAB V HASIL DAN PEMBAHASAN.....	71
5.1 Evaluasi Model.....	71
5.1.1 Confusion Matrix	72
5.1.2 Classification Report.....	73
5.2 Analisis Komparatif (Grab vs Gojek)	77
5.3 Deployment.....	78
BAB VI KESIMPULAN DAN SARAN	80
6.1 Kesimpulan	80
6.2 Saran.....	81
DAFTAR PUSTAKA	82

DAFTAR GAMBAR

Gambar 2.1 Alur Penelitian SVM	18
Gambar 2.2 Logo Gojek.....	31
Gambar 2.3 Logo Grab	32
Gambar 2.4 Logo Phyton	34
Gambar 3.1 Kerangka Berpikir	41
Gambar 3.2 Alur Penelitian.....	49
Gambar 4.1 Dataset Ulasan Gojek yang Diakses pada Google Colab.....	56
Gambar 4.2 Dataset Ulasan Grab yang Diakses pada Google Colab	57
Gambar 4.3 Evaluasi Gojek	63
Gambar 4.4 Evaluasi Grab	64
Gambar 4.5 Evaluasi Model Gojek.....	65
Gambar 4.6 Evaluasi Model Grab.....	65
Gambar 5.1 Hasil Laporan Klasifikasi (<i>Classification Report</i>) Gojek	73
Gambar 5.2 Hasil Laporan Klasifikasi (<i>Classification Report</i>) Grab	74

DAFTAR TABEL

Tabel 2.1 Studi Literatur	36
Tabel 4.1 Sampel Dataset Hasil <i>Scraping</i>	53
Tabel 4.2 Contoh Hasil Preprocessing	58
Tabel 5.1 Perbandingan Akurasi Model	77
Tabel 5.2 Hasil Pengujian Model pada Data Baru	79

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan komunikasi yang sangat pesat di era industri 4.0 telah membawa transformasi fundamental pada berbagai sektor kehidupan, termasuk industri transportasi dan layanan berbasis on-demand di Indonesia. Kehadiran super-app seperti Grab dan Gojek tidak hanya mengubah pola mobilitas masyarakat, tetapi juga menciptakan ekosistem ekonomi baru yang menjadi sumber penghasilan bagi jutaan mitra pengemudi (driver). Kedua platform ini kini telah menjadi bagian tak terpisahkan dari kehidupan masyarakat perkotaan dengan volume transaksi harian yang sangat masif.

Gojek, yang didirikan pada tahun 2010 sebagai layanan call center, telah berevolusi menjadi decacorn dengan beragam layanan mulai dari transportasi hingga pembayaran digital (Yuniar & Kismiantini, 2023). Sementara itu, Grab yang bermula di Malaysia pada tahun 2012, kini juga mendominasi pasar Asia Tenggara dengan strategi layanan terintegrasi (Nurfauzi et al., 2025). Persaingan ketat di antara kedua raksasa teknologi ini secara tidak langsung menciptakan standar ekspektasi yang tinggi dari sisi konsumen, sehingga menuntut adanya evaluasi kualitas layanan yang berkelanjutan agar perusahaan dapat mempertahankan loyalitas pengguna di tengah persaingan pasar yang dinamis.

Salah satu indikator utama kualitas layanan dapat dilihat dari ulasan pengguna (user reviews) di Google Play Store. Ulasan ini berisi opini jujur mengenai pengalaman transaksi, performa aplikasi, hingga perilaku mitra pengemudi. Namun, dengan jumlah ulasan yang mencapai ratusan ribu, analisis secara manual menjadi tidak efisien dan rentan terhadap subjektivitas. Oleh karena itu, diperlukan pendekatan komputasi seperti

Analisis Sentimen untuk mengolah data tersebut menjadi informasi yang terstruktur.

Selain perspektif sebagai pengguna, peneliti juga memiliki pengalaman langsung sebagai mitra pengemudi (driver) pada kedua platform tersebut. Pengalaman di lapangan memberikan gambaran nyata mengenai keluhan dan apresiasi yang sering disampaikan penumpang, baik secara lisan maupun melalui aplikasi. Observasi empiris ini memperkuat urgensi penelitian untuk memvalidasi fenomena lapangan tersebut menggunakan data ilmiah berupa ulasan publik. Keluhan pelanggan yang sering ditemukan di lapangan, baik mengenai sistem promosi yang membingungkan maupun kendala teknis pada aplikasi, menjadi motivasi kuat bagi peneliti untuk memvalidasi fenomena lapangan tersebut menggunakan metodologi ilmiah yang objektif berbasis data ulasan publik.

Dalam ranah analisis sentimen, pemilihan algoritma klasifikasi sangat menentukan akurasi hasil. Berbagai penelitian terdahulu telah membandingkan performa algoritma pembelajaran mesin. Misalnya, penelitian (Hidayat & Sulistiyono, 2022) menunjukkan bahwa algoritma Support Vector Machine (SVM) memiliki keunggulan dalam menangani data teks berdimensi tinggi dibandingkan metode lain seperti Naive Bayes. SVM terbukti mampu memisahkan hyperplane antar kelas sentimen dengan margin yang optimal, sehingga menghasilkan akurasi yang lebih baik pada dataset ulasan aplikasi.

Penggunaan algoritma SVM dalam penelitian ini didasarkan pada ketangguhan metode tersebut dalam melakukan klasifikasi pada dataset yang memiliki karakteristik noise yang tinggi. Ulasan pada Google Play Store seringkali menggunakan bahasa yang tidak baku, singkatan yang tidak standar, serta adanya fenomena *code-mixing* (campuran bahasa Indonesia dan Inggris). SVM bekerja dengan mencari *optimal hyperplane* yang memaksimalkan jarak antar kelas, sehingga tetap stabil dan memiliki generalisasi yang baik meskipun menghadapi variasi kosakata yang sangat luas dalam teks ulasan.

Penelitian ini difokuskan pada penggunaan dataset sebanyak 1.995 ulasan untuk masing-masing aplikasi (total 3.990 data). Pemilihan jumlah data ini bertujuan khusus untuk menguji batas kemampuan dan efektivitas algoritma SVM dalam mengolah data skala menengah tanpa harus melakukan generalisasi terhadap kepuasan pengguna secara menyeluruh. Dengan fokus pada aspek teknis klasifikasi, penelitian ini diharapkan dapat memberikan gambaran sejauh mana SVM mampu mengenali pola sentimen pada ulasan layanan transportasi yang sangat dinamis, sebelum nantinya diterapkan pada dataset yang lebih masif secara *real-time*.

Berdasarkan latar belakang tersebut, penelitian ini bertujuan untuk melakukan komparasi analisis sentimen pengguna aplikasi Grab dan Gojek dengan menerapkan metode Support Vector Machine (SVM) dan pembobotan TF-IDF, guna mengklasifikasikan ulasan ke dalam kategori positif, negatif, dan netral secara otomatis.

1.2 Identifikasi Masalah

Berdasarkan latar belakang di atas, maka dapat diidentifikasi beberapa permasalahan sebagai berikut:

1. Banyaknya ulasan pengguna aplikasi Grab dan Gojek di Google Play Store yang belum dimanfaatkan secara optimal sebagai bahan evaluasi layanan.
2. Data ulasan masih berupa teks tidak terstruktur yang bercampur antara sentimen positif, negatif, dan netral, menyulitkan pihak pengembang untuk mengetahui persepsi pengguna secara cepat.
3. Perlunya mengetahui perbandingan sentimen positif, negatif, dan netral antara pengguna aplikasi Grab dan Gojek untuk melihat keunggulan dan kelemahan masing-masing layanan.

1.3 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana penerapan algoritma Support Vector Machine (SVM) dalam menganalisis sentimen ulasan pengguna aplikasi Grab dan Gojek di Google Play Store?
2. Bagaimana tingkat akurasi algoritma Support Vector Machine (SVM) dalam mengklasifikasikan sentimen ulasan menjadi positif, negatif, dan netral?

1.4 Batasan Masalah

Agar penelitian ini terarah dan fokus sesuai tujuan yang telah ditetapkan, maka diperlukan batasan masalah sebagai berikut:

1. Objek penelitian difokuskan pada ulasan pengguna aplikasi Grab dan Gojek yang diambil dari platform Google Play Store. Ulasan dari media sosial lain seperti Twitter, Facebook, atau Instagram tidak termasuk dalam lingkup penelitian ini.
2. Bahasa data ulasan yang digunakan dibatasi pada ulasan berbahasa Indonesia untuk menjaga konsistensi dalam proses *preprocessing* dan analisis sentimen.
3. Metode analisis yang digunakan adalah Support Vector Machine (SVM) dengan pendekatan Linear Support Vector Classification (LinearSVC) dan pembobotan fitur menggunakan Term Frequency–Inverse Document Frequency (TF-IDF).
4. Kategori sentimen yang digunakan dibatasi pada tiga kelas utama, yaitu:
 - ~ Positif,
 - ~ Negatif, dan
 - ~ Netral,sesuai standar umum pada penelitian analisis sentimen berbasis teks
5. Data penelitian bersifat sekunder dan diambil dari sumber terbuka (Google Play Store reviews). Peneliti tidak melakukan survei langsung kepada pengguna Grab dan Gojek.

1.5 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dipaparkan, maka tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Menerapkan algoritma Support Vector Machine (SVM) untuk analisis sentimen ulasan pengguna aplikasi Grab dan Gojek.
2. Mengukur akurasi model Support Vector Machine (SVM) dalam mengklasifikasikan sentimen ulasan dari kedua perspektif (pengguna dan driver).

1.6 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat:

1. Bagi Perusahaan (Grab & Gojek): Sebagai bahan evaluasi untuk meningkatkan kualitas aplikasi dan layanan bagi pengguna dan driver.
2. Bagi Pengguna dan Driver: Memberikan gambaran objektif mengenai pengalaman masing-masing pihak.
3. Bagi Peneliti: Menjadi referensi dalam pengembangan analisis sentimen menggunakan metode Support Vector Machine (SVM) pada data ulasan aplikasi.

1.7 Ruang Lingkup Penelitian

Penelitian ini dibatasi pada:

1. Data ulasan aplikasi Grab dan Gojek diambil dari Google Play Store.
2. Analisis sentimen dilakukan menggunakan algoritma Support Vector Machine (SVM) dengan pendekatan LinearSVC.
3. Representasi fitur teks menggunakan pembobotan TF-IDF dengan kombinasi n-gram (1,2).
4. Evaluasi model dilakukan menggunakan confusion matrix serta metrik accuracy, precision, recall, dan F1-score.
5. Pembahasan hasil dilakukan berdasarkan klasifikasi sentimen positif, negatif, dan netral dari perspektif pengguna.

1.8 Sistematika Penulisan

Sistematika penulisan yang akan dilakukan dalam penelitian ini terdiri dari 6 bab, yaitu:

BAB I PENDAHULUAN

Dalam bab ini akan dibahas mengenai latar belakang, rumusan masalah, tujuan penelitian, manfaat penelitian dan ruang lingkup penelitian.

BAB II LANDASAN TEORI

Dalam bab ini akan dibahas mengenai berbagai teori yang mendasari analisis permasalahan dan berhubungan dengan topik yang dibahas.

BAB III METODOLOGI PENELITIAN

Dalam bab ini membahas mengenai metodologi yang akan digunakan dan langkah-langkah untuk melakukan penelitian.

BAB IV IMPLEMENTASI

Pada bab ini, akan membahas tentang simulasi sistem dari mulai perancangan sampai pengujian sistem yang sesuai dengan metode yang digunakan.

BAB V HASIL DAN PEMBAHASAN

Pada bab ini, akan disajikan hasil dan pembahasan dari penelitian yang dilakukan.

BAB VI PENUTUP

Pada bab ini, berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran yang dapat diberikan untuk pengembangan penelitian selanjutnya.

BAB II

LANDASAN TEORI

2.1 Analisis Sentimen

Analisis sentimen merupakan proses untuk mengidentifikasi, mengekstraksi, dan mengklasifikasikan opini atau emosi yang terkandung dalam suatu teks terhadap suatu objek atau peristiwa. Hasil analisis sentimen umumnya dikategorikan ke dalam tiga kelas utama, yaitu sentimen positif, negatif, dan netral. Perkembangan teknologi informasi dan meningkatnya penggunaan media digital menyebabkan banyak pengguna internet mengekspresikan pendapat, pengalaman, serta opini mereka dalam bentuk teks, termasuk dalam ulasan aplikasi pada platform seperti Google Play Store (Samanmali & Rupasingha, 2024).

Secara umum, analisis sentimen dipandang sebagai permasalahan klasifikasi teks. Dalam konteks ini, sistem akan mempelajari pola dari data teks untuk menentukan label sentimen pada setiap dokumen atau kalimat. Setiap teks dianalisis untuk mengetahui kecenderungan opini yang terkandung di dalamnya, apakah bersifat positif, negatif, atau netral.

Proses analisis sentimen biasanya melibatkan beberapa tahapan utama, yaitu:

1. Identifikasi Sentimen pada Setiap Teks menentukan polaritas sentimen (positif, negatif, atau netral) pada setiap baris atau dokumen teks.
2. Klasifikasi Dokumen Secara Keseluruhan mengelompokkan teks berdasarkan kecenderungan sentimen yang paling dominan.
3. Pengelompokan Berdasarkan Kategori Sentimen mengelompokkan seluruh data ke dalam kelas sentimen yang sama untuk dianalisis lebih lanjut.

4. Visualisasi Hasil Analisis menyajikan hasil klasifikasi dalam bentuk grafik atau diagram untuk mempermudah interpretasi dan pengambilan keputusan.


Analisis sentimen dapat dilakukan melalui dua pendekatan utama, yaitu pendekatan lexicon-based dan pendekatan machine learning (Waspodo et al., 2022).

Dalam penelitian ini, analisis sentimen dilakukan menggunakan pendekatan machine learning dengan algoritma Support Vector Machine (SVM), yang terbukti efektif dalam menangani klasifikasi teks berbasis fitur berdimensi tinggi.

Dalam konteks penelitian ini, analisis sentimen diterapkan untuk mengetahui persepsi pengguna terhadap layanan aplikasi Grab dan Gojek. (Hajaroh et al., 2024)

2.2 Natural Language Processing (NLP)

Natural Language Processing (NLP) atau Pemrosesan Bahasa Alami merupakan bidang interdisipliner dari kecerdasan buatan (*Artificial Intelligence*) dan linguistik komputasi yang berfokus pada interaksi antara komputer dan bahasa manusia. Tujuan utama dari NLP dalam penelitian ini adalah agar komputer mampu memahami, menafsirkan, serta memproses bahasa yang digunakan oleh pengguna aplikasi Grab dan Gojek dalam ulasan mereka secara otomatis dan akurat. Integrasi komponen NLP dalam **Sistem Analisis Sentimen** pada penelitian ini secara komprehensif diilustrasikan pada **Gambar X** di bawah ini:



Gambar 2. 1 Arsitektur Sistem Analisis Sentimen Berbasis NLP dan SVM

Berdasarkan visualisasi pada Gambar 2.1, dapat dilihat bahwa sistem analisis sentimen ini beroperasi sebagai sebuah *pipeline* yang mengintegrasikan berbagai komponen teknis. Proses dimulai dari akuisisi data ulasan dari Google Play Store dan media sosial (diwakili oleh logo Google Play, X, dan Twitter di kedua sisi). Data ulasan dari pengguna aplikasi Grab dan Gojek ini bersifat *raw* (mentah) dan sangat bervariasi.

Dalam konteks analisis sentimen, NLP bertindak sebagai jembatan yang mengubah data teks yang bersifat tidak terstruktur (*unstructured data*) menjadi format data yang terstruktur. Tantangan utama dalam NLP untuk dataset ulasan dari Google Play Store adalah adanya variasi bahasa yang sangat luas, mulai dari penggunaan bahasa gaul (*slang*), singkatan yang tidak standar, hingga kesalahan pengetikan (*typo*).

Elemen krusial NLP dalam sistem ini berada di bagian tengah Gambar 2.1, yaitu "Pre-processing Data (NLP)", yang digambarkan seperti sebuah corong penyaring. Pada tahap inilah data ulasan mentah diproses melalui empat langkah teknis inti yang diimplementasikan dalam penelitian ini:

1. Case Folding: Penyeragaman huruf kapital menjadi huruf kecil untuk menghilangkan ambiguitas data.
2. Tokenizing: Pemecahan teks ulasan menjadi potongan-potongan kata (*token*) agar setiap kata dapat diproses secara terpisah.
3. Stopword Removal: Penghapusan kata-kata yang tidak memiliki muatan sentimen yang kuat. Proses ini sering kali didukung oleh teknik pembobotan seperti TF-IDF, di mana kata-kata umum (seperti "dan", "yang", "di") diberikan bobot yang sangat rendah agar tidak menjadi *noise* bagi model klasifikasi.
4. Stemming (Indonesian): Proses pengubahan kata berimbuhan menjadi kata dasar (misalnya "memuaskan" menjadi "muas"). Di Indonesia, proses ini menuntut penanganan linguistik khusus, seperti penggunaan algoritma Sastrawi.

Setelah melalui corong pre-processing ini, data teks yang kini terstruktur diumpankan ke "Model SVM" di bagian bawah. Ilustrasi Confusion Matrix visual menunjukkan bagaimana SVM bekerja dalam menarik garis pemisah (optimal hyperplane) untuk mengklasifikasikan data ke dalam label sentimen yang akurat. Hasil akhir sistem, berupa metrik Akurasi dan Presisi untuk masing-masing aplikasi, serta visualisasi Word Cloud, merupakan keluaran dari seluruh pipeline NLP yang diintegrasikan dengan algoritma klasifikasi.

Integrasi NLP dan SVM seperti pada Gambar X ini membuktikan bahwa keberhasilan model klasifikasi sangat bergantung pada kualitas pre-processing teks yang dilakukan. Tanpa NLP, data ulasan akan terlalu berisik untuk dapat diinterpretasikan secara akurat oleh algoritma *machine learning*.

2.3 Text Mining

Text mining, atau sering disebut juga sebagai penambangan data teks, merupakan sebuah proses komprehensif yang bertujuan untuk mengekstraksi informasi berharga, pola tersembunyi, hingga tren tertentu

dari kumpulan data teks yang bersifat tidak terstruktur (unstructured data). Perbedaan mendasar antara text mining dengan data mining konvensional terletak pada objek datanya; jika data mining bekerja pada data numerik yang telah tertata rapi dalam basis data, maka text mining harus berhadapan dengan kompleksitas bahasa manusia seperti yang ditemukan pada dokumen, komentar media sosial, ulasan aplikasi, hingga artikel berita.

Dalam pengaplikasiannya, text mining memanfaatkan teknik Natural Language Processing (NLP) sebagai instrumen utama untuk menjembatani interaksi antara bahasa manusia dengan logika komputer. Melalui NLP, teks mentah ditransformasikan menjadi representasi data terstruktur yang dapat diolah oleh algoritma komputasi. Menurut (Lin & Nuha, 2023) efektivitas text mining sangat bergantung pada alur kerja sistematis yang meliputi tahapan preprocessing data, ekstraksi fitur (representasi numerik), serta proses klasifikasi atau analisis lanjut.

Dalam penelitian ini, text mining berperan sebagai kerangka kerja utama untuk mengolah ribuan ulasan pengguna aplikasi Grab dan Gojek. Tujuannya adalah mengubah opini mentah pelanggan yang bersifat sangat subjektif dan beragam menjadi dataset yang valid untuk dianalisis menggunakan algoritma Support Vector Machine (SVM), sehingga mampu menghasilkan klasifikasi sentimen yang akurat.

Pada tahap preprocessing, teks dibersihkan dan dinormalisasi melalui proses seperti case folding, penghapusan tanda baca, stopword removal, dan stemming. Selanjutnya, teks direpresentasikan ke dalam bentuk numerik melalui teknik ekstraksi fitur seperti Term Frequency–Inverse Document Frequency (TF-IDF). Representasi numerik inilah yang kemudian digunakan sebagai input bagi algoritma machine learning untuk melakukan klasifikasi sentimen.

Dalam penelitian ini, text mining digunakan untuk mengolah data ulasan aplikasi Grab dan Gojek yang bersifat tidak terstruktur menjadi data terstruktur yang dapat dianalisis menggunakan algoritma Support Vector Machine (SVM).

2.4 Preprocessing Data Teks

Preprocessing merupakan tahapan krusial dalam siklus text mining yang berfungsi untuk melakukan pembersihan (cleansing) dan normalisasi terhadap data teks sebelum masuk ke tahap pemodelan. Urgensi dari tahap ini didasari oleh karakteristik data teks mentah, khususnya ulasan pada platform digital, yang umumnya mengandung banyak gangguan (noise). Noise tersebut dapat berupa simbol-simbol yang tidak relevan, penggunaan tanda baca yang berlebihan, hingga variasi penulisan kata yang tidak standar. Tanpa preprocessing yang tepat, performa model klasifikasi akan menurun drastis karena sistem kesulitan mengenali fitur-fitur penting dalam teks. Selain itu, tahap preprocessing juga membantu menyederhanakan representasi teks sehingga lebih terstruktur dan mudah diproses oleh algoritma machine learning. Dengan demikian, kualitas data yang dihasilkan menjadi lebih optimal dan mampu meningkatkan akurasi serta keandalan model klasifikasi yang dibangun.

Tahapan preprocessing ini mencakup serangkaian prosedur teknis yang meliputi:

1. Case Folding

Proses penyeragaman seluruh karakter huruf dalam teks menjadi huruf kecil (lowercase). Hal ini dilakukan untuk menjamin bahwa sistem tidak membedakan makna kata berdasarkan penggunaan huruf kapital, sehingga kata seperti "Grab", "GRAB", dan "grab" akan dianggap sebagai satu entitas yang sama.

2. Tokenizing

Merupakan prosedur untuk memecah rangkaian kalimat atau paragraf ulasan menjadi unit-unit kata yang berdiri sendiri (token). Melalui tokenisasi, setiap kata dapat diidentifikasi posisinya dan dianalisis frekuensi kemunculannya sebagai komponen penyusun sentimen secara terpisah.

3. Stopword Removal

Proses eliminasi kata-kata umum yang memiliki frekuensi kemunculan tinggi namun tidak memiliki kontribusi makna yang signifikan dalam konteks analisis sentimen. Kata-kata seperti "dan", "yang", "di", atau "ke" dihapus agar model hanya fokus pada kata-kata bermakna kuat yang dapat merepresentasikan opini positif atau negatif.

4. Stemming

Teknik transformasi kata berimbuhan kembali ke bentuk kata dasarnya. Dalam konteks bahasa Indonesia, *stemming* sangat penting untuk menyeragamkan kata-kata yang memiliki akar kata yang sama namun berbeda imbuhan (misalnya "memesan", "pesanan", dan "dipesan" menjadi "pesan"). Proses ini membantu mengurangi dimensi fitur teks dan meningkatkan akurasi dalam pengenalan pola sentimen.

5. Filtering / Noise Removal

Selain tahap di atas, dilakukan juga penghapusan karakter khusus, angka, serta alamat URL (jika ada) yang seringkali menyertai ulasan di Google Play Store. Langkah tambahan ini memastikan bahwa dataset yang tersisa benar-benar murni berisi teks ulasan yang informatif bagi algoritma klasifikasi.

2.5 Google Play Store sebagai Sumber Data

Google Play Store merupakan platform distribusi aplikasi digital terbesar yang dikembangkan oleh Google, yang berfungsi sebagai perantara utama antara pengembang aplikasi dengan pengguna global. Selain sebagai media unduhan, platform ini menyediakan fitur krusial berupa sistem ulasan (*review*) dan penilaian (*rating*) bintang yang bersifat publik. Ulasan yang diberikan oleh pengguna aplikasi mencerminkan opini mentah, pengalaman nyata di lapangan, serta evaluasi kritis terhadap kualitas layanan, stabilitas fitur, hingga performa antarmuka aplikasi tersebut (Amrie et al., 2022). Oleh karena itu, Google Play Store menjadi repositori data yang sangat kaya untuk memahami persepsi pasar secara *real-time*.

Secara teknis, data ulasan pada Google Play Store tergolong sebagai data yang tidak terstruktur (*unstructured data*) karena berbentuk teks bebas yang ditulis secara spontan oleh pengguna dengan gaya bahasa yang sangat beragam. Tantangan dalam mengolah data ini terletak pada adanya penggunaan bahasa gaul (*slang*), singkatan tidak standar, kesalahan pengetikan (*typo*), serta penggunaan emotikon yang bercampur dengan teks formal. Karakteristik data yang dinamis ini mengharuskan adanya implementasi teknik *Text Mining* dan *Natural Language Processing* (NLP)

agar informasi yang terkandung di dalamnya dapat diekstraksi dan dianalisis secara sistematis sesuai dengan kaidah komputasi.

Dalam penelitian ini, ulasan pengguna dari aplikasi Grab Customer dan Gojek Customer yang diperoleh melalui Google Play Store digunakan sebagai sumber data primer untuk proses analisis sentimen. Keunggulan penggunaan data dari platform ini adalah objektivitasnya, di mana pengguna cenderung memberikan *feedback* yang jujur berdasarkan pengalaman langsung menggunakan jasa transportasi daring tersebut. Data yang berhasil dihimpun kemudian melewati serangkaian prosedur metodologis, mulai dari tahap *preprocessing* untuk pembersihan teks, ekstraksi fitur menggunakan metode TF-IDF guna mendapatkan bobot kata yang representatif, hingga tahap akhir yakni klasifikasi menggunakan algoritma *Support Vector Machine* (SVM). Melalui pendekatan ini, data ulasan yang semula acak dapat dikategorikan secara akurat ke dalam polaritas sentimen positif, negatif, atau netral, yang pada akhirnya memberikan gambaran komprehensif mengenai tingkat kepuasan pelanggan terhadap kedua aplikasi tersebut.

2.6 CRISP-DM

Model penelitian ini mengadopsi kerangka kerja **CRISP-DM**, yang merupakan standar proses industri yang paling umum digunakan dalam proyek pengembangan data sains dan *machine learning*. Pendekatan ini dipilih karena memiliki alur yang terstruktur, siklis, dan sangat fleksibel untuk menangani proyek berbasis data teks. Tahapan tersebut mencakup enam fase utama sebagai berikut:

a. Business Understanding

Tahap awal ini difokuskan pada identifikasi tujuan strategis penelitian dari sudut pandang kebutuhan analisis. Peneliti mendefinisikan masalah utama, yaitu perlunya mengetahui persepsi publik terhadap layanan transportasi daring yang sangat kompetitif di Indonesia. Fokus utamanya

adalah menganalisis sentimen pengguna aplikasi Grab dan Gojek di Google Play Store serta mengukur sejauh mana algoritma *Support Vector Machine* (SVM) mampu mengklasifikasikan data tersebut ke dalam kategori positif, negatif, dan netral secara akurat. Penentuan metrik keberhasilan di awal sangat krusial agar seluruh proses analisis data tetap selaras dengan rumusan masalah yang telah ditetapkan.

b. Data Understanding

Tahap awal ini difokuskan pada identifikasi tujuan strategis penelitian dari sudut pandang kebutuhan analisis. Peneliti mendefinisikan masalah utama, yaitu perlunya mengetahui persepsi publik terhadap layanan transportasi daring yang sangat kompetitif di Indonesia. Fokus utamanya adalah menganalisis sentimen pengguna aplikasi Grab dan Gojek di Google Play Store serta mengukur sejauh mana algoritma *Support Vector Machine* (SVM) mampu mengklasifikasikan data tersebut ke dalam kategori positif, negatif, dan netral secara akurat. Penentuan metrik keberhasilan di awal sangat krusial agar seluruh proses analisis data tetap selaras dengan rumusan masalah yang telah ditetapkan.

c. Data Preparation

Ini adalah fase yang paling memakan waktu karena teks mentah harus dikonversi menjadi format terstruktur yang dapat "dibaca" oleh komputer. Proses pembersihan mencakup *case folding*, tokenisasi, *stopword removal*, dan *stemming* khusus bahasa Indonesia. Setelah data bersih, teks ditransformasikan menjadi representasi vektor numerik menggunakan metode **TF-IDF** (*Term Frequency–Inverse Document Frequency*). Peneliti juga melakukan pembagian data (*data splitting*) menjadi data latih (*training set*) dan data uji (*testing set*) guna memastikan model memiliki data yang cukup untuk belajar dan divalidasi.

d. Modeling

Pada tahap ini, algoritma *Support Vector Machine* (SVM) diimplementasikan sebagai mesin pengklasifikasi utama. Peneliti memilih jenis kernel yang sesuai (seperti *Linear Kernel*) untuk memetakan data ke

dalam ruang fitur yang optimal guna menemukan *hyperplane* pemisah terbaik. Proses eksperimen dilakukan dengan mengatur parameter model agar mampu menangkap pola sentimen yang kompleks dari ulasan pengguna. Model dilatih menggunakan data latih dan disempurnakan hingga mencapai tingkat konvergensi yang diinginkan.

e. Evaluation

Setelah model terbentuk, fase evaluasi dilakukan untuk mengukur performa model secara objektif. Peneliti menggunakan instrumen **Confusion Matrix** untuk melihat seberapa banyak data yang terklasifikasi dengan benar maupun salah. Metrik evaluasi yang dihitung mencakup *Accuracy*, *Precision*, *Recall*, dan *F1-Score*. Evaluasi ini bertujuan bukan hanya untuk melihat angka keberhasilan, tetapi juga untuk menganalisis mengapa model mengalami kesalahan klasifikasi pada kelas tertentu, sehingga memberikan pemahaman yang lebih dalam mengenai keterbatasan model yang dibangun.

f. Deployment

Tahap akhir dalam siklus CRISP-DM pada penelitian ini direalisasikan dalam bentuk penyajian hasil analisis yang komprehensif dalam laporan penelitian. Hasil dari klasifikasi dan evaluasi model digunakan sebagai fondasi dalam menarik kesimpulan ilmiah serta memberikan rekomendasi strategis bagi pengembang aplikasi maupun peneliti selanjutnya. Dokumentasi proses dari awal hingga akhir memastikan bahwa model ini dapat direplikasi atau dikembangkan lebih lanjut di masa depan.

2.7 Support Vector Machine (SVM)


Support Vector Machine (SVM) merupakan algoritma *supervised learning* yang sangat populer dan tangguh dalam menangani permasalahan klasifikasi serta regresi, baik linier maupun non-linier. Prinsip kerja utama SVM adalah dengan memetakan data ke dalam ruang fitur berdimensi tinggi untuk kemudian mencari sebuah *hyperplane* (bidang pemisah) optimal yang mampu membagi dataset ke dalam kelas-kelas yang berbeda secara akurat.

Dalam konteks analisis sentimen, *hyperplane* ini berfungsi sebagai batas keputusan yang memisahkan antara ulasan berkategori positif, negatif, maupun netral.

Menurut (Mulugeta et al., 2023), tujuan utama dari algoritma SVM adalah menemukan *hyperplane* yang memiliki jarak atau margin terbesar terhadap titik data terdekat dari masing-masing kelas. Titik-titik data yang berada paling dekat dengan *hyperplane* ini disebut sebagai *support vectors*, yang secara kritis menentukan posisi dan orientasi dari bidang pemisah tersebut. Dengan memaksimalkan margin, model SVM diharapkan dapat meminimalisir kesalahan klasifikasi dan meningkatkan kemampuan generalisasi saat dihadapkan pada data baru yang belum pernah dilihat sebelumnya (*unseen data*).

Salah satu keunggulan utama SVM, khususnya dalam pengolahan bahasa alami (*Natural Language Processing*), adalah kemampuannya yang sangat efisien dalam menangani *high-dimensional data*. Dalam penelitian ini, setelah ulasan pengguna melalui proses TF-IDF, setiap dokumen akan direpresentasikan sebagai vektor dengan ribuan dimensi. SVM mampu bekerja dengan baik pada ruang dimensi tinggi tersebut tanpa mengalami kendala *overfitting* yang berarti. Selain itu, SVM memiliki fleksibilitas melalui penggunaan fungsi kernel (seperti *Linear*, *Polynomial*, atau *Radial Basis Function*) yang memungkinkan algoritma untuk mengubah data yang tidak dapat dipisahkan secara linier menjadi dapat dipisahkan pada dimensi yang lebih tinggi.

Implementasi SVM dalam klasifikasi sentimen aplikasi Grab dan Gojek ini memanfaatkan kelebihan tersebut untuk mengenali pola-pola kata yang kompleks. Dengan batas keputusan yang optimal, algoritma ini mampu membedakan nuansa bahasa yang halus dalam ulasan pelanggan, sehingga menghasilkan prediksi label sentimen yang memiliki tingkat akurasi dan reliabilitas tinggi.



Gambar 2. 2 Alur Penelitian SVM

2.7.1 Linear SVM dan Optimal Hyperplane

Dalam kasus *linearly separable*, SVM menentukan *hyperplane* pemisah dengan margin jarak maksimal antar kelas.

Teorema 1 (Optimal Hyperplane) "Diberikan sekumpulan data latih (x_i, y_i) dimana $x_i \in R^n$ dan $y_i \in \{-1, +1\}$, jika data tersebut dapat dipisahkan secara linear, maka terdapat satu hyperplane pemisah optimal yang memaksimumkan margin antara dua kelas tersebut."

Secara matematis, fungsi keputusan SVM dapat dituliskan sebagai berikut:

$$w \cdot x + b = 0$$

Di mana :

- **w** adalah vektor bobot (weight vector),
- **x** adalah vektor fitur,
- **b** adalah bias.

Data yang terletak tepat pada batas margin disebut sebagai Support Vectors, yang memenuhi pertidaksamaan pada Teorema 2.

Teorema 2 (Canonical Hyperplane) "Hyperplane kanonik adalah hyperplane yang memenuhi kondisi $y_i(w \cdot x_i + b) \geq 1$ untuk semua data $i = 1, \dots, N$. Jarak (margin) antara dua kelas didefinisikan sebagai $\frac{2}{|w|}$."

Berdasarkan Teorema 2, untuk mendapatkan pemisah terbaik, kita harus memaksimumkan nilai margin $\frac{2}{|w|}$ yang ekuivalen dengan meminimalkan nilai $|w|^2$. Maka, masalah optimasi SVM dapat dituliskan sebagai:

$$\min \frac{1}{2} |w|^2 \quad \text{dengan syarat} \quad y_i(w \cdot x_i + b) \geq 1$$

2.7.2 Non-Linear SVM dan Kernel Trick

Pada data dunia nyata (seperti ulasan teks), data seringkali tidak dapat dipisahkan secara linear. Untuk mengatasi ini, SVM memetakan data ke dimensi yang lebih tinggi (fitur space) agar dapat dipisahkan. Teknik ini didasari oleh Teorema Mercer.

Teorema 3 (Teorema Mercer) "Fungsi Kernel $K(x_i, x_j)$ dapat digunakan untuk menghitung hasil kali titik (dot product) di ruang dimensi tinggi tanpa perlu mengetahui transformasi fungsi $\phi(x)$ secara eksplisit, asalkan fungsi kernel tersebut memenuhi kondisi simetris dan positif semi-definit."

Penerapan Teorema 3 memungkinkan SVM menangani data non-linear dengan mengganti operasi hasil kali titik menjadi fungsi Kernel, seperti pada Persamaan

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

2.7.3 Jenis-Jenis Fungsi Kernel

Dalam mengimplementasikan *Kernel Trick*, terdapat beberapa jenis fungsi kernel yang umum digunakan, di mana pemilihannya sangat bergantung pada distribusi serta karakteristik data yang dihadapi. Konsep dasar dari *Kernel Trick* adalah kemampuannya untuk mentransformasikan data yang awalnya tidak dapat dipisahkan secara linear di ruang dimensi rendah menjadi data yang dapat dipisahkan secara linear di ruang dimensi yang lebih tinggi (*feature space*) tanpa harus menghitung koordinat data di ruang tersebut secara eksplisit. Pemilihan fungsi kernel ini menjadi faktor krusial karena sangat menentukan bagaimana *hyperplane* dibentuk dan bagaimana model melakukan generalisasi terhadap pola ulasan pengguna. Beberapa fungsi kernel yang sering diimplementasikan antara lain:

1. Kernel Linear

Linear Kernel digunakan apabila distribusi data dalam ruang fitur dapat dipisahkan secara linear tanpa memerlukan transformasi ke dimensi yang lebih tinggi. Dalam klasifikasi teks, kernel ini menjadi pilihan paling efisien dan fundamental karena memiliki kompleksitas komputasi terendah, sehingga proses pelatihan model berlangsung lebih cepat.

Keunggulan utama *Linear Kernel* dalam analisis sentimen adalah kemampuannya menangani dataset berdimensi tinggi (*high-dimensional*), seperti hasil ekstraksi fitur TF-IDF. Mengingat data teks cenderung sudah bersifat *linearly separable* di ruang aslinya, penggunaan kernel ini efektif untuk meminimalisir risiko *overfitting*.

Secara teknis, *Linear Kernel* bekerja dengan menghitung hasil kali titik (*dot product*) secara langsung antara dua vektor input. Operasi ini merepresentasikan proyeksi satu vektor

terhadap vektor lainnya untuk menentukan tingkat kemiripan (*similarity score*) antar dokumen ulasan. Karena tidak melibatkan transformasi fungsi non-linear, parameter yang perlu dioptimasi oleh peneliti menjadi lebih sedikit, sehingga risiko kegagalan model akibat salah konfigurasi parameter dapat diminimalisir. Rumus matematis untuk *Linear Kernel* didefinisikan sebagai berikut

$$K(x, x_i) = x \cdot x_i$$

Di mana x dan x_i merepresentasikan vektor fitur dari data yang sedang dibandingkan. Hasil dari operasi ini kemudian digunakan oleh algoritma SVM untuk menentukan posisi hyperplane yang paling optimal dalam memisahkan kelas-kelas sentimen

2. Kernel Polynomial

Polynomial Kernel digunakan untuk memetakan data ke dalam ruang fitur yang lebih kompleks dengan derajat tertentu (d). Berbeda dengan *Linear Kernel* yang hanya mencari garis pemisah lurus, kernel ini mampu membentuk batas keputusan yang bersifat non-linear dan melengkung, sehingga sangat efektif untuk menangani dataset yang distribusi kelasnya tidak dapat dipisahkan secara sederhana.

Dalam konteks analisis sentimen, *Polynomial Kernel* bekerja dengan cara merepresentasikan interaksi antar-fitur (kata) melalui kombinasi polinomial. Hal ini memungkinkan model untuk menangkap hubungan yang lebih dalam antara kata-kata tertentu yang mungkin hanya memiliki makna sentimen kuat jika muncul secara bersamaan. Penggunaan kernel ini sangat bergantung pada penentuan derajat (d) yang tepat; derajat yang rendah mungkin

gagal menangkap kompleksitas data, sementara derajat yang terlalu tinggi berisiko meningkatkan beban komputasi secara signifikan serta memicu terjadinya *overfitting*. Secara matematis, rumus untuk *Polynomial Kernel* didefinisikan sebagai berikut:

$$K(x, x_i) = (x \cdot x_i + c)^d$$

Di mana x dan x_i merepresentasikan vektor fitur dari data yang sedang dibandingkan dalam ruang dimensi tinggi. Dengan mengatur nilai-nilai parameter tersebut, algoritma SVM dapat fleksibel dalam membangun *hyperplane* yang paling sesuai dengan pola persepsi pengguna pada ulasan Grab dan Gojek.

3. Kernel Radial Basis Function (RBF) / Gaussian


Radial Basis Function (RBF), atau yang sering dikenal sebagai kernel Gaussian, merupakan fungsi kernel yang paling populer dan paling luas penggunaannya dalam berbagai aplikasi *Machine Learning*. Keunggulan utama dari kernel ini adalah kemampuannya untuk menangani pemetaan data ke dalam ruang fitur dengan dimensi yang tidak terhingga (*infinite dimensional space*). Karakteristik ini membuat RBF sangat efektif digunakan untuk menangani dataset ulasan teks yang memiliki pola sebaran tidak beraturan atau memiliki batas pemisah antar kelas yang sangat kompleks dan tidak linear.

Dalam proses klasifikasi sentimen, RBF bekerja dengan mengukur tingkat kemiripan (*similarity*) antara dua titik data berdasarkan jarak Euclidean di antara keduanya. Semakin dekat jarak antara dua ulasan dalam ruang fitur, maka semakin besar nilai kemiripan yang dihasilkan. Penentuan nilai gamma yang tepat sangat krusial; nilai yang terlalu tinggi dapat menyebabkan model menjadi *overfitting*, sedangkan nilai yang terlalu rendah

dapat mengakibatkan model gagal menangkap pola data yang kompleks (*underfitting*). Secara matematis, rumus untuk kernel RBF didefinisikan sebagai berikut:

$$K(x, x_i) = \exp\left(-\gamma \|x - x_i\|^2\right)$$

Di mana parameter γ (gamma) mengontrol sejauh mana pengaruh satu titik data pelatihan mencapai titik lainnya.



Gambar 2. 3 Visualisasi Perbandingan Batas Keputusan (*Decision Boundaries*) Berbagai Kernel SVM

Gambar 2.2 memberikan ilustrasi visual mengenai bagaimana empat varian kernel SVM bekerja dalam membentuk *hyperplane* pada dataset yang sama. **(a) SVC linear kernel** dan **(b) LinearSVC** keduanya menghasilkan batas keputusan berupa garis lurus, yang sangat optimal jika data dapat dipisahkan secara linier tanpa transformasi rumit. Perbedaan keduanya terletak pada efisiensi komputasi, di mana LinearSVC lebih unggul untuk dataset skala besar. Pada panel **(c) SVC RBF kernel**, batas keputusan tampak melengkung dan sangat adaptif terhadap sebaran data. Kernel ini menjadi standar dalam analisis teks karena fleksibilitasnya dalam

menangani pola data yang kompleks. Sementara itu, **(d) SVC polynomial (degree 3)** membentuk kurva yang mengikuti pola data dengan derajat tertentu, memungkinkan model menangkap interaksi antar fitur yang tidak bisa diakomodasi oleh kernel linear. Pemilihan kernel ini sangat menentukan sejauh mana model mampu melakukan generalisasi terhadap sentimen pengguna.

2.8 Perbandingan Algoritma Klasifikasi

Dalam penelitian analisis sentimen, pemilihan algoritma klasifikasi memegang peranan krusial dalam menentukan tingkat akurasi model yang dibangun. Selain Support Vector Machine (SVM), algoritma lain yang sering menjadi pembanding dalam pengolahan teks adalah Naive Bayes Classifier (NBC). Naive Bayes merupakan metode klasifikasi yang berdasar pada probabilitas sederhana dengan asumsi kuat bahwa setiap fitur (kata dalam ulasan) bersifat independen atau tidak memiliki keterkaitan satu sama lain.

Meskipun Naive Bayes memiliki keunggulan dari sisi kecepatan komputasi, namun dalam menangani data teks ulasan aplikasi yang bersifat spontan, algoritma ini seringkali terkendala oleh asumsi independensi tersebut. Teks ulasan pengguna Grab dan Gojek umumnya memiliki keterkaitan makna antar kata yang kompleks atau kontekstual. Berdasarkan pengujian awal yang dilakukan pada penelitian ini menggunakan metode Naive Bayes, diperoleh tingkat akurasi sebesar 69% untuk dataset Gojek dan 70% untuk dataset Grab. Hasil tersebut menunjukkan bahwa Naive Bayes belum mampu menangani kompleksitas fitur bahasa dalam dataset ini secara maksimal. Di sinilah letak keunggulan utama SVM. Berbeda dengan Naive Bayes, SVM bekerja dengan mencari optimal hyperplane yang memisahkan kelas sentimen dengan margin maksimal di ruang dimensi tinggi. Hal ini membuat SVM jauh lebih tangguh dalam menangani data teks yang memiliki banyak fitur (vokabulari luas), serta lebih stabil dalam

menghadapi noise seperti penggunaan bahasa gaul, singkatan yang tidak standar, maupun fenomena code-mixing.

Keunggulan performa SVM dibandingkan Naive Bayes telah divalidasi oleh berbagai penelitian sebelumnya. Salah satunya adalah penelitian oleh (Nurfauzi et al., 2025) mengenai analisis sentimen Grab Indonesia, di mana algoritma SVM terbukti memberikan hasil yang lebih stabil pada ulasan Google Play Store. Selain itu, penelitian (Wiguna et al., 2023) pada dataset ojek online menunjukkan hasil yang sangat signifikan, di mana SVM berhasil memperoleh nilai akurasi sebesar 90%, mengungguli Naive Bayes yang hanya mencapai akurasi 77%. Selisih akurasi tersebut memperkuat alasan penggunaan SVM dalam penelitian ini karena kemampuannya dalam melakukan generalisasi pola sentimen yang lebih akurat pada data teks yang tidak terstruktur.

2.9 TF-IDF (Term Frequency-Inverse Document Frequency)

Term Frequency–Inverse Document Frequency (TF-IDF) merupakan metode ekstraksi fitur yang digunakan untuk mengukur tingkat kepentingan suatu kata dalam sebuah dokumen relatif terhadap seluruh dokumen dalam suatu korpus. Metode ini banyak digunakan dalam pengolahan teks karena mampu memberikan bobot lebih tinggi pada kata yang sering muncul dalam suatu dokumen tetapi jarang muncul pada dokumen lain.

Proses pembobotan **Term Frequency-Inverse Document Frequency (TF-IDF)** dalam penelitian ini merupakan tahap krusial untuk mentransformasi data tekstual menjadi vektor numerik yang dapat diproses oleh algoritma **Support Vector Machine (SVM)**. Secara visual, prinsip kerja pembobotan ini dapat diilustrasikan pada Gambar X.

Pada ilustrasi tersebut, terlihat bahwa kata-kata fungsional yang sering muncul dalam hampir seluruh dokumen namun kurang memiliki makna spesifik—seperti kata hubung atau partikel "**dan**", "**di**", dan "**yang**"—akan diberikan bobot yang lebih rendah melalui mekanisme **Inverse Document Frequency (IDF)**. Hal ini dilakukan karena kata-kata tersebut dianggap

tidak memiliki kekuatan diskriminatif untuk membedakan antara satu sentimen dengan sentimen lainnya.

Sebaliknya, kata-kata yang memiliki nilai informasi tinggi dan bersifat spesifik terkait sentimen—seperti "**judes**", "**ramah**", atau "**tunggu**"—akan diberikan bobot yang lebih besar oleh algoritma. Kata-kata ini cenderung memiliki frekuensi kemunculan yang tinggi pada kategori sentimen tertentu namun jarang muncul di kategori lainnya, sehingga dianggap sebagai fitur kunci yang merepresentasikan opini pengguna.

Untuk memberikan gambaran yang lebih jelas mengenai bagaimana data teks diolah, **Gambar X** di bawah ini mengilustrasikan logika penentuan bobot kata menggunakan metode TF-IDF:



Gambar 2. 4 Ilustrasi Logika Pembobotan Kata dengan TF-IDF

Berdasarkan ilustrasi di atas, proses seleksi fitur bekerja layaknya sebuah timbangan yang mengevaluasi tingkat kepentingan sebuah kata:

Sisi Timbangan Kiri (Bobot Rendah): Terlihat kata-kata seperti "dan", "di", dan "yang" berada pada posisi timbangan yang lebih tinggi (ringan). Dalam konteks ulasan Grab dan Gojek, kata-kata ini disebut sebagai stopwards. Karena kata-kata ini muncul hampir di setiap ulasan pengguna, algoritma memberikan nilai Inverse Document Frequency (IDF) yang sangat rendah. Hal ini bertujuan agar kata-kata fungsional tersebut tidak

mendominasi proses klasifikasi karena tidak memiliki muatan informasi sentimen.

Sisi Timbangan Kanan (Bobot Tinggi): Terlihat kata-kata seperti "judes", "ramah", dan "tunggu" berada pada posisi timbangan yang lebih rendah (berat). Kata-kata ini memiliki nilai Term Frequency (TF) yang signifikan pada kategori sentimen tertentu. Misalnya, kata "judes" sering muncul pada sentimen negatif, sedangkan "ramah" muncul pada sentimen positif. Karena kata-kata ini jarang muncul di seluruh dokumen secara umum tetapi sering muncul pada kelas tertentu, maka algoritma memberikan bobot yang tinggi.

Pemberian bobot yang berbeda ini sangat krusial bagi performa Support Vector Machine (SVM). Dengan "memberatkan" kata-kata yang bermakna sentimen seperti pada gambar tersebut, model SVM akan lebih mudah dalam menarik garis pemisah (hyperplane) yang akurat. Sebagai contoh, jika sebuah ulasan mengandung kata dengan bobot tinggi seperti "judes", maka koordinat vektor ulasan tersebut akan tertarik kuat ke arah area kelas negatif pada ruang dimensi fitur.

Secara umum, pembobotan TF-IDF merupakan hasil perkalian antara dua metrik statistik, yaitu *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF). Nilai bobot ini menunjukkan seberapa penting sebuah kata dalam suatu dokumen terhadap keseluruhan korpus atau dataset ulasan Grab dan Gojek. Formulasi matematis untuk menentukan bobot kata dirumuskan sebagai berikut:

$$W_{d,t} = TF_{d,t} \times IDF_t$$

Di mana :

$$TF_{d,t} = \frac{f_{d,t}}{\max(f_d)}$$

$$IDF_t = \log\left(\frac{D}{df_t}\right)$$

Keterangan:

- $W_{d,t}$ = bobot term t pada dokumen d
- $TF_{d,t}$ = frekuensi kemunculan term t dalam dokumen d
- $f_{d,t}$ = jumlah kemunculan term t dalam dokumen d
- $\max(f_d)$ = frekuensi tertinggi dalam dokumen d
- IDF_t = inverse document frequency dari term t
- D = jumlah total dokumen dalam korpus
- df_t = jumlah dokumen yang mengandung term t


Dalam penelitian ini, TF-IDF digunakan untuk mengubah data teks hasil preprocessing menjadi representasi numerik berbentuk vektor fitur. Representasi ini kemudian digunakan sebagai input bagi algoritma Support Vector Machine (SVM) dalam proses klasifikasi sentimen.

Penting untuk dipahami bahwa pemberian bobot dalam TF-IDF menggunakan skala Logaritma (Log-Normalization). Penggunaan fungsi logaritma dalam rumus $IDF = \log\left(\frac{N}{df}\right)$ bertujuan untuk menormalisasi pengaruh jumlah dokumen. Tanpa logaritma, nilai IDF akan menjadi terlalu besar dan mendominasi nilai Term Frequency (TF), sehingga kata-kata yang sangat langka akan mendapatkan bobot yang tidak proporsional (terlalu ekstrem).

Selain itu, fungsi logaritma memberikan efek *diminishing returns*, yang secara matematis berarti peningkatan frekuensi kata dalam dokumen tidak meningkatkan bobot kata tersebut secara linear. Hal ini merepresentasikan kenyataan dalam bahasa manusia bahwa kata yang muncul 100 kali dalam satu dokumen tidak berarti 100 kali lebih penting daripada kata yang muncul 1 kali. Skala logaritma membantu menyeimbangkan distribusi bobot tersebut agar model SVM dapat mengenali fitur kata yang benar-benar relevan sebagai pembeda antar kelas sentimen.

2.10 Confusion Matrix

Confusion Matrix merupakan sebuah instrumen evaluasi berbentuk tabel yang digunakan untuk mendeskripsikan kinerja model klasifikasi secara komprehensif. Tabel ini bekerja dengan cara membandingkan nilai prediksi yang dihasilkan oleh sistem terhadap label aktual (ground truth) yang ada pada dataset (Rahardi et al., n.d.) Dalam konteks penelitian analisis sentimen dengan tiga kelas kategori, yaitu positif, negatif, dan netral. Visualisasi dari struktur *Confusion Matrix* dapat dilihat pada Gambar 2.5:



Gambar 2. 5 Ilustrasi Struktur Confusion Matrix

Berdasarkan Gambar 2.5, dapat dijelaskan bahwa Confusion Matrix terdiri dari baris dan kolom yang merepresentasikan distribusi hasil prediksi:

1. Sumbu Actual (Vertikal): Baris mewakili kelas atau label sentimen yang sebenarnya pada dataset.
2. Sumbu Predicted (Horizontal): Kolom mewakili kelas atau label sentimen yang diprediksi oleh model SVM.

Penggunaan Confusion Matrix sangat krusial karena akurasi saja seringkali tidak cukup untuk merepresentasikan performa model secara objektif, terutama jika terdapat ketidakseimbangan jumlah data pada tiap kelas sentimen. Dari tabel ini, dapat diturunkan beberapa metrik evaluasi utama sebagai berikut:

- **Akurasi (*Accuracy*):** Merupakan metrik yang paling mendasar untuk mengukur tingkat keberhasilan model dalam mengklasifikasikan data secara benar. Akurasi dihitung dengan membagi total prediksi yang tepat (positif, negatif, dan netral yang tertebak benar) dengan seluruh jumlah data yang diuji.

$$\text{Akurasi: } \frac{TPP + TNegNeg + TNetNet}{Total}$$

- **Presisi (*Precision*):** Metrik ini mengukur tingkat keakuratan antara data yang diminta dengan hasil prediksi yang diberikan oleh model. Dalam skenario kelas positif, presisi menunjukkan sejauh mana model dapat membedakan data yang benar-benar positif dari sekumpulan data yang diprediksi sebagai positif (termasuk kesalahan *false positive*).

$$\text{Presisi: } \frac{TPP}{(TPP + NegFP + NetFP)}$$

- **Recall (*Sensitivity*):** Metrik ini menggambarkan keberhasilan model dalam menemukan kembali (*retrieve*) seluruh data yang termasuk dalam kategori kelas tertentu. *Recall* yang tinggi menunjukkan bahwa model mampu meminimalisir adanya data aktual yang tidak terdeteksi oleh sistem (*false negative*).

$$\text{Recall: } \frac{TPP}{(TPP + PFNeg + PFNet)}$$

- **F1-Score:** Merupakan rata-rata harmonik antara presisi dan *recall* yang berfungsi untuk mengevaluasi keseimbangan performa model. Metrik ini sangat efektif digunakan pada dataset dengan distribusi kelas yang tidak seimbang (*imbalanced data*) guna memberikan gambaran akurasi yang lebih objektif

$$.F1\text{-Score: } 2 \times \frac{(Presisi \times Recall)}{(Presisi + Recall)}$$

2.11 Gojek



Gambar 2.6 Logo Gojek

Gojek didirikan pada tahun 2010 oleh Nadiem Makarim sebagai layanan panggilan ojek konvensional di Jakarta (Asmawati et al., 2025). Ide mendasar pembentukan platform ini bersumber dari pengamatan personal Nadiem Makarim terhadap inefisiensi pasar transportasi ojek kala itu, di mana ia sering mengalami kesulitan dalam menemukan pengemudi ojek, terutama pada saat kondisi cuaca buruk seperti hujan.

Seiring dengan perkembangan teknologi *mobile*, Gojek melakukan transformasi besar pada tahun 2015 dengan meluncurkan aplikasi berbasis Android dan iOS. Transformasi ini mengubah model bisnis dari *call center* menjadi *on-demand service platform* yang menghubungkan konsumen dengan pengemudi secara *real-time*. Kini, Gojek telah berevolusi menjadi sebuah *Super App* yang tidak hanya menyediakan layanan transportasi, namun juga merambah ke berbagai sektor seperti pengiriman makanan (GoFood), pembayaran digital (GoPay), hingga logistik. Ekspansi bisnis yang masif ini telah memposisikan Gojek sebagai salah satu perusahaan *decacorn* pertama di Indonesia yang memberikan dampak signifikan terhadap pertumbuhan ekonomi digital nasional.

2.12 Grab



Gambar 2.7 Logo Grab

Grab didirikan pada tahun 2012 di Malaysia oleh Anthony Tan dan Tan Hooi Ling, yang pada awalnya beroperasi di bawah entitas nama 'MyTeksi'. Pendirian platform ini dilatarbelakangi oleh keinginan untuk merevolusi industri taksi konvensional yang saat itu dinilai kurang aman dan tidak efisien. Grab kemudian melakukan ekspansi strategis ke pasar Indonesia pada tahun 2014 dengan memperkenalkan layanan 'GrabTaxi' sebagai solusi transportasi berbasis aplikasi yang lebih terorganisir bagi masyarakat urban (Alghifari et al., 2022).

Fokus fundamental Grab pada masa awal operasionalnya adalah memprioritaskan faktor keamanan, terutama bagi penumpang wanita, guna membangun kepercayaan publik terhadap transportasi berbasis daring. Seiring dengan pertumbuhan pengguna yang masif, Grab bertransformasi menjadi perusahaan *multinational technology* yang memindahkan kantor pusatnya ke Singapura dan melakukan *branding* ulang menjadi 'Grab' untuk mencakup berbagai lini layanan. Saat ini, Grab telah berkembang melampaui layanan transportasi (*ride-hailing*), dengan mengintegrasikan ekosistem layanan digital seperti pengiriman makanan (GrabFood), pengiriman paket (GrabExpress), hingga layanan finansial (GrabPay). Keberhasilan Grab dalam mengakuisisi operasional Uber di Asia Tenggara pada tahun 2018 semakin memperkuat posisinya sebagai salah satu *super-app* terbesar yang menguasai pangsa pasar di kawasan tersebut.

2.13 Perangkat Pengembangan (*Development Tools*)

Dalam penelitian ini, implementasi sistem dilakukan dengan mengintegrasikan berbagai perangkat lunak dan bahasa pemrograman pendukung yang dipilih secara selektif untuk menjamin efektivitas serta validitas hasil analisis data dan pemodelan. Penggunaan perangkat pengembangan ini bukan sekadar alat bantu teknis, melainkan instrumen krusial dalam menyederhanakan alur kerja pengolahan data yang kompleks, mulai dari tahap pembersihan teks (*preprocessing*) hingga tahap pemodelan prediktif menggunakan algoritma *Machine Learning*. Pemilihan *tools* yang bersifat *open-source* dan standar dalam disiplin ilmu *Data Science* ini memastikan bahwa seluruh proses komputasi dalam analisis sentimen ulasan Grab dan Gojek dapat dilakukan secara sistematis, akurat, dan dapat dipertanggungjawabkan secara teknis.

2.13.1 Bahasa Pemrograman Python

Python merupakan bahasa pemrograman tingkat tinggi (*high-level programming language*) bersifat *open-source* yang telah menjadi standar industri global, khususnya dalam disiplin ilmu *Data Science*, *Artificial Intelligence*, serta *Machine Learning*. Bahasa ini pertama kali dikembangkan oleh Guido van Rossum dan dirilis secara resmi pada tahun 1991 dengan filosofi desain yang sangat menekankan pada keterbacaan kode dan efisiensi pengembangan. Keunggulan fundamental Python terletak pada sintaksnya yang sederhana, bersih, dan minimalis yang menyerupai struktur bahasa Inggris, sehingga memungkinkan para pengembang serta peneliti untuk lebih fokus pada logika penyelesaian masalah dan pengembangan algoritma daripada terjebak dalam kerumitan teknis penulisan kode yang bersifat *low-level*. Keunggulan utama Python terletak pada sintaksnya yang sederhana dan minimalis, sehingga memungkinkan pengembang untuk fokus pada logika penyelesaian masalah daripada kerumitan teknis penulisan kode (Adebayo et al., 2023).



Gambar 2. 8 Logo Python

Dalam penelitian ini, Python dipilih karena memiliki ekosistem pustaka (*library*) yang sangat luas dan matang, khususnya dalam menangani tugas-tugas *Natural Language Processing* (NLP). Pustaka-pustaka tersebut memungkinkan proses integrasi data mentah menjadi informasi yang siap diolah secara efisien, antara lain::

- **Pandas:** Berfungsi sebagai pustaka utama dalam manajemen data yang menyediakan struktur data *DataFrame*. Hal ini memudahkan peneliti dalam melakukan pembersihan, seleksi, dan transformasi dataset ulasan yang bertipe data terstruktur seperti CSV.
- **Scikit-learn:** Berfungsi sebagai pustaka utama dalam manajemen data yang menyediakan struktur data *DataFrame*. Hal ini memudahkan peneliti dalam melakukan pembersihan, seleksi, dan transformasi dataset ulasan yang bertipe data terstruktur seperti CSV.

- **Sastrawi:** Mengingat dataset yang digunakan adalah ulasan berbahasa Indonesia, pustaka Sastrawi menjadi instrumen krusial untuk melakukan *stemming* dan *stopword removal* sesuai dengan kaidah tata bahasa Indonesia.
- **Matplotlib/Seaborn:** Digunakan untuk menciptakan visualisasi data yang informatif, seperti grafik distribusi frekuensi sentimen dan *heatmap* untuk *confusion matrix*, guna mempermudah interpretasi hasil penelitian.

2.13.2 Google Colaboratory

Google Colaboratory atau sering disebut Google Colab adalah layanan berbasis cloud dari Google yang memungkinkan pengguna untuk menulis dan mengeksekusi kode Python langsung melalui browser tanpa perlu melakukan instalasi di komputer lokal (Oliver, 2022). Google Colab dibangun di atas lingkungan Jupyter Notebook dan menyediakan akses gratis ke sumber daya komputasi yang kuat, termasuk GPU (Graphics Processing Unit).

Fitur ini sangat memudahkan peneliti dalam melakukan eksperimen analisis sentimen karena semua library pendukung Data Science umumnya sudah terpasang secara default, serta memudahkan proses kolaborasi dan penyimpanan kode yang terintegrasi langsung dengan Google Drive.



Gambar 2. 9 Google Colab

2.14 Studi Literatur

Tabel 2. 1 Studi Literatur

No	Judul	Penulis	Tahun	Algoritma	Hasil	Kelebihan	kekuranganS
1	Analisa Sentimen Terhadap Penggunaan Aplikasi Shopee Food Pada Twitter Menggunakan Metode Naïve Bayes Dan Support Vector Machine (SVM)	Pratama	2022	SVM, Naïve Bayes	Penelitian ini membandingkan akurasi antara Naïve Bayes dan SVM. Hasilnya digunakan untuk evaluasi kebijakan Shopee Food berdasarkan opini positif dan negatif masyarakat di Twitter.	Mengkomparasi dua algoritma populer (SVM dan Naïve Bayes) secara langsung untuk mendapatkan model terbaik.	Hanya berfokus pada data Twitter yang memiliki karakteristik teks pendek dan banyak <i>slang</i> , belum mencakup ulasan Play Store.
2	Analisis Sentimen Gojek Indonesia Pada Twitter Menggunakan Algoritme Naïve Bayes Dan Support Vector Machine	Khoiruddin	2023	Naïve Bayes dan Support Vector Machine (SVM)	Akurasi Naive Bayes 91%, SVM 99%.	SVM lebih akurat untuk data kompleks; cocok untuk analisis media sosial.	SVM lebih lambat dalam pelatihan; preprocessing intensif.
3	Analisis Sentimen Terhadap Perbandingan Kepuasan Pengguna Jasa Ojek Online dengan Metode Support Vector Machine (SVM)	Amaliah	2024	Support Vector Machine (SVM)	Penelitian ini mampu mengklasifikasikan sentimen pengguna (Positif/Negatif) dengan akurasi tinggi, serta memberikan perbandingan kualitas layanan ojek <i>online</i>	Fokus pada perbandingan kepuasan pengguna secara langsung, memberikan <i>insight</i> kompetitif bagi penyedia layanan.	Lingkup data terbatas pada pengguna di wilayah tertentu sehingga belum sepenuhnya merepresentasikan tren nasional.

4	Analisis Sentimen Berita Online Terhadap Transportasi Online di Indonesia dengan Metode Naïve Bayes Classifier, Support Vector Machine dan K-Nearest Neighbor	Selawati, et al.	2025	Naïve Bayes, SVM, KNN	Penelitian ini membandingkan tiga algoritma untuk mengklasifikasikan sentimen pemberitaan transportasi online dan mengevaluasi performa akurasi masing-masing model.	Membandingkan tiga metode klasifikasi sekaligus (NBC, SVM, KNN) untuk mendapatkan validitas model terbaik.	Membandingkan tiga metode klasifikasi sekaligus (NBC, SVM, KNN) untuk mendapatkan validitas model terbaik.
5	Sentiment Analysis of Public Responses Regarding the Use of Electric Cars in Indonesia with Support Vector Machine and Random Forest Methods	Seraphina & Gunawan	2025	SVM, Random Forest	Hasil eksperimen menunjukkan bahwa Random Forest memperoleh akurasi tertinggi sebesar 90,72%, lebih tinggi dibandingkan SVM (Kernel Linear) dengan akurasi 89,28%.	Membandingkan kernel SVM (Linear, RBF, Polynomial) dan variasi estimator Random Forest untuk menentukan konfigurasi terbaik.	Dataset berasal dari media sosial X (Twitter) dengan karakteristik teks tidak baku dan singkat, berbeda dengan ulasan di Google Play Store.
6	Data Mining Untuk Memprediksi Tingkat Kepuasan Konsumen Gojek	Rudika Rahman & Felix Andreas Sutanto	2023	Naive Bayes, Confusion Matrix	Akurasi 88,9% dengan 120 data (84 training, 36 testing)	Data primer dari kuesioner memberikan konteks langsung. Sistem berbasis web dengan UI lengkap.	Ukuran dataset kecil dan tidak ada perbandingan dengan metode lain. Tidak menangani sentimen netral.
7	Sentiment Analysis of On-Demand Ride-Hailing Systems using Support Vector Machine and Naïve Bayes	Wiguna, et al.	2023	SVM, Naïve Bayes	Hasil pengujian menunjukkan bahwa algoritma SVM jauh lebih unggul dengan akurasi 90% , presisi 91%, dan F1-score 94%, dibandingkan Naïve Bayes yang hanya mencapai akurasi 77%.	Melakukan komparasi langsung dua algoritma populer pada ulasan Gojek, membuktikan superioritas SVM dalam menangani dataset ulasan aplikasi.	Hanya berfokus pada label sentimen positif dan negatif (klasifikasi biner), mengabaikan sentimen netral yang mungkin ada pada ulasan pengguna.

8	Perbandingan Kinerja Support Vector Machine Dan Random Forest Untuk Klasifikasi Sentimen Pengguna Aplikasi Gojek Dengan Optimasi SMOTE	Rihastuti & Rosyidi	2025	SVM, Random Forest, SMOTE	Hasil pengujian menunjukkan bahwa Random Forest lebih unggul dengan akurasi 84,1% , sedangkan SVM mencapai akurasi 76,1% . Penggunaan SMOTE terbukti efektif menyeimbangkan kelas data pada tahap <i>training</i> .	Menerapkan teknik SMOTE untuk mengatasi masalah data tidak seimbang (<i>imbalanced dataset</i>) dan menggunakan uji statistik (<i>Paired t-test</i>) untuk memvalidasi signifikansi hasil.	Dalam studi kasus spesifik ini, performa SVM terbukti lebih rendah dibandingkan Random Forest, dan jumlah dataset yang digunakan relatif terbatas (2.000 ulasan).
9	Sentiment Analysis Terhadap Review Aplikasi Maxim di Google Play Store Menggunakan Support Vector Machine (SVM)	Akbar, et al.	2022	Support Vector Machine (SVM)	Penelitian ini menganalisis sentimen pengguna terhadap aplikasi Maxim. Penerapan metode SVM pada data ulasan Google Play Store menghasilkan tingkat akurasi sebesar 79% .	Mengangkat studi kasus pada aplikasi Maxim sebagai pembanding kompetitor utama (Gojek/Grab), memberikan wawasan baru di luar dua pemain besar tersebut.	Akurasi yang dihasilkan (79%) masih tergolong standar dibandingkan penelitian lain yang menggunakan teknik optimasi tambahan atau <i>deep learning</i> .
10	Analisis Sentimen Terhadap Pengguna Gojek Dan Grab Pada Media Sosial Twitter Menggunakan Random Forest	Melia, et al.	2023	Random Forest	Penelitian ini membandingkan sentimen publik terhadap dua raksasa transportasi online. Hasil klasifikasi menunjukkan bahwa Grab mendominasi sentimen positif sebesar 77,33% , sedangkan Gojek hanya memperoleh sentimen positif sebesar 37,20%.	Menggunakan data media sosial Twitter yang sangat dinamis untuk membandingkan persepsi publik secara <i>head-to-head</i> antara Gojek dan Grab.	Metode yang digunakan (Random Forest) memerlukan waktu <i>training</i> yang lebih lama dibandingkan SVM, terutama ketika jumlah pohon keputusan (<i>decision trees</i>) diperbanyak.

BAB III

METODE PENELITIAN

3.1 Kerangka Berpikir

Kerangka berpikir dalam penelitian ini disusun sebagai landasan sistematis untuk memecahkan masalah analisis sentimen pada ulasan pengguna aplikasi Grab dan Gojek di Google Play Store. Alur pemikiran ini mengadopsi standar industri **CRISP-DM** yang terdiri dari enam tahapan terintegrasi, yang dirancang untuk memastikan proses pengolahan data mentah menjadi informasi strategis berjalan secara akurat.

1. Business Understanding (Memahami Kebutuhan Bisnis)

Tahap awal dimulai dengan mengidentifikasi urgensi dari opini publik terhadap layanan transportasi daring. Di tengah persaingan ketat antara Grab dan Gojek, sentimen pengguna merupakan aset krusial. Kerangka ini bertujuan untuk mengubah tumpukan ulasan tekstual yang tidak terstruktur menjadi label kategori (positif dan negatif) yang dapat diukur, guna memberikan rekomendasi perbaikan layanan bagi pengembang aplikasi.

2. Data Understanding (Memahami Karakteristik Data)

Setelah tujuan ditetapkan, dilakukan eksplorasi terhadap data ulasan yang diperoleh melalui teknik scraping. Tahap ini mencakup pengecekan terhadap jumlah sampel, variasi rating bintang, serta identifikasi awal terhadap kualitas teks ulasan, seperti adanya penggunaan bahasa gaul (slang), singkatan, maupun inkonsistensi penulisan yang umum ditemukan pada platform digital.

3. Data Preparation (Pra-pemrosesan Teks)

Tahapan ini merupakan fase paling krusial dalam Natural Language Processing (NLP). Teks ulasan yang masih kotor harus melalui serangkaian proses transformasi agar siap diolah oleh algoritma, yang meliputi:

- **Cleansing:** Menghapus angka, simbol, URL, dan tanda baca.
- **Case Folding:** Menyamakan semua huruf menjadi huruf kecil.
- **Tokenizing:** Memecah kalimat menjadi potongan kata tunggal.
- **Normalisasi:** Mengubah kata tidak baku menjadi kata baku (misal: "yg" menjadi "yang").
- **Filtering (Stopword Removal):** Membuang kata-kata yang tidak memiliki makna signifikan dalam analisis sentimen (misal: "dan", "di", "ke").
- **Stemming:** Mengembalikan kata berimbuhan menjadi kata dasar menggunakan library *Sastrawi* agar konsistensi fitur terjaga.
- **Pembobotan Kata (TF-IDF):** Mengonversi teks menjadi representasi angka berdasarkan frekuensi kemunculannya.

4. Modeling (Implementasi Algoritma SVM)

Pada tahap ini, kerangka berpikir difokuskan pada penerapan algoritma Support Vector Machine (SVM). Data yang telah diproses dibagi menjadi data latih (training data) dan data uji (testing data). SVM bekerja dengan mencari hyperplane optimal yang memisahkan antara sentimen positif dan negatif dengan margin maksimal. Pemilihan kernel (seperti Linear atau RBF) dilakukan untuk memastikan model mampu menangani dimensi data yang tinggi secara efisien.


5. Evaluation (Evaluasi Kinerja Model)

Setelah model terbentuk, dilakukan pengujian menggunakan Confusion Matrix. Kerangka berpikir ini menekankan pada pengukuran performa melalui beberapa metrik utama, yaitu:

- **Accuracy:** Seberapa sering model benar dalam memprediksi label.
- **Precision:** Rasio prediksi positif yang benar-benar positif.
- **Recall:** Rasio kemampuan model menemukan kembali informasi sentimen yang ada.
- **F1-Score:** Keseimbangan antara *precision* dan *recall*. Evaluasi ini memastikan bahwa model tidak hanya akurat secara angka, tetapi juga memiliki kemampuan generalisasi yang baik terhadap data baru.

6. Deployment (Implementasi dan Visualisasi)

Tahap akhir dari kerangka berpikir ini adalah *deployment*, di mana hasil klasifikasi sentimen divisualisasikan dalam bentuk grafik atau dasbor yang mudah dipahami. Hasil akhirnya memberikan gambaran perbandingan sentimen antara Grab dan Gojek, yang dapat digunakan oleh pihak manajemen sebagai bahan evaluasi strategis untuk meningkatkan kepuasan pengguna di masa mendatang.



Gambar 3. 1 Kerangka Berpikir

3.2 Metode Pengumpulan Data

1. Studi Literatur

Tahap studi literatur dilakukan sebagai langkah awal yang fundamental untuk membangun kerangka pemikiran yang sistematis dan komprehensif dalam penelitian ini. Penulis melakukan pengkajian secara mendalam terhadap berbagai referensi ilmiah yang memiliki relevansi langsung dengan topik analisis sentimen pada layanan transportasi daring. Sumber literatur utama diperoleh dari jurnal ilmiah nasional maupun internasional, prosiding konferensi, tesis, serta buku-buku teknis yang berfokus pada domain *Text Mining*, *Natural Language Processing* (NLP), dan *Machine Learning*. Melalui tinjauan pustaka ini, penulis dapat memetakan tren teknologi pengolahan bahasa alami sekaligus mengidentifikasi celah penelitian (*research gap*) yang dapat dikembangkan lebih lanjut guna memberikan nilai kebaruan dalam studi ini.

Proses ini tidak hanya sebatas pengumpulan data sekunder, tetapi juga melibatkan analisis komparatif terhadap algoritma *Support Vector Machine* (SVM) untuk memahami keunggulan metodologi tersebut dalam menangani data teks yang bersifat tidak terstruktur (*unstructured data*). Selain itu, studi literatur mencakup pendalaman teknik *preprocessing* khusus bahasa Indonesia, seperti *stemming* dan *stopword removal*, guna memastikan tahap pengolahan data tetap selaras dengan standar kaidah kebahasaan dan mampu meminimalisir ambiguitas makna pada ulasan pengguna.

Pengkajian ini juga berfungsi secara strategis untuk menentukan parameter optimal dalam ekstraksi fitur menggunakan metode TF-IDF, sehingga bobot setiap kata dapat merepresentasikan sentimen secara akurat. Tujuan utamanya adalah untuk memperkuat landasan teoretis, menghindari duplikasi penelitian yang tidak perlu, serta memberikan dukungan metodologis yang valid dalam merancang model klasifikasi sentimen pengguna Grab dan Gojek. Dengan demikian, hasil akhir penelitian diharapkan memiliki integritas ilmiah yang tinggi serta dapat dipertanggungjawabkan di hadapan para penguji.

2. Wawancara

Tahapan wawancara diimplementasikan sebagai bagian integral dari studi pendahuluan (*preliminary study*) guna memperkuat urgensi serta rumusan masalah dalam penelitian ini. Penulis melakukan proses tanya jawab secara lisan melalui pendekatan tidak terstruktur (*unstructured interview*) untuk mendapatkan wawasan langsung yang lebih mendalam dan autentik. Proses penggalian informasi ini difokuskan kepada dua kelompok subjek utama yang berinteraksi langsung dengan ekosistem transportasi daring, yaitu:

- Mitra Pengemudi (Driver): Mewawancarai rekan sesama mitra pengemudi Grab dan Gojek untuk mengetahui keluhan yang sering dialami terkait performa aplikasi di lapangan (seperti maps tidak akurat, bug orderan, atau skema insentif).
- Pengguna Aplikasi (User): Wawancara juga dilakukan terhadap beberapa pengguna aktif yang secara rutin memanfaatkan layanan transportasi daring. Tujuannya adalah untuk memahami persepsi subjektif mereka terhadap kualitas layanan serta menggali motivasi di balik pemberian *rating* atau ulasan tertentu di Google Play Store. Hal ini memberikan gambaran mengenai aspek apa saja yang paling memengaruhi tingkat kepuasan pelanggan secara personal.

Meskipun hasil dari wawancara ini tidak diposisikan sebagai dataset utama dalam proses pelatihan model (mengingat data latih sepenuhnya diperoleh melalui metode *scraping*), namun data kualitatif yang dihasilkan berperan vital sebagai instrumen validasi. Hasil tanya jawab ini berfungsi untuk mengonfirmasi bahwa permasalahan kualitas layanan yang ditemukan memang benar-benar terjadi secara nyata di lapangan. Dengan demikian, penggunaan sistem klasifikasi sentimen otomatis berbasis *Machine Learning* dalam penelitian ini memiliki landasan empiris yang kuat untuk menganalisis permasalahan tersebut dalam skala yang lebih luas.

3. Observasi dan Pengumpulan Data Ulasan Pengguna Aplikasi

Tahapan ini merupakan proses inti dalam penyediaan dataset yang akan digunakan untuk eksperimen. Peneliti melakukan observasi secara digital terhadap tren ulasan pengguna pada platform Google Play Store untuk mengidentifikasi pola sentimen pelanggan terhadap layanan transportasi daring. Proses pengumpulan data dilakukan secara otomatis menggunakan teknik *web scraping* dengan memanfaatkan pustaka (*library*) Python. Penggunaan teknik ini memungkinkan peneliti untuk mengekstraksi data dalam volume besar secara efisien dan akurat dibandingkan dengan pengambilan data secara manual.

Data ulasan yang diambil secara spesifik difokuskan pada aplikasi **Grab Customer** dan **Gojek Customer** (versi pengguna), bukan aplikasi mitra pengemudi. Hal ini dilakukan untuk memastikan bahwa dataset yang terkumpul murni merepresentasikan pengalaman pelanggan dari sisi pengguna layanan. Untuk menjaga keadilan dalam proses komparasi performa model nantinya, peneliti menentukan jumlah sampel yang seimbang (*balanced*) antara kedua objek penelitian. Adapun rincian distribusi data yang digunakan dalam penelitian ini adalah sebagai berikut:

- **Dataset Gojek:** Terdiri dari 1.995 ulasan pengguna yang mencakup berbagai variasi *rating* dari skala 1 hingga 5. 1.995 ulasan pengguna aplikasi Gojek
- **Dataset Grab:** Terdiri dari 1.995 ulasan pengguna dengan karakteristik distribusi yang serupa guna menjaga konsistensi perbandingan. 1.995 ulasan pengguna aplikasi Grab

Sehingga total data ulasan yang digunakan adalah 3.990 data. Data tersebut selanjutnya digunakan sebagai dataset untuk proses preprocessing teks, pelabelan sentimen menggunakan pendekatan berbasis rating (*rating-based*), ekstraksi fitur menggunakan TF-IDF, serta klasifikasi sentimen menggunakan algoritma Support Vector Machine (SVM).

3.3 Metode Implementasi Eksperimen

Penelitian ini menggunakan pendekatan CRISP-DM (Cross Industry Standard Process for Data Mining) sebagai kerangka kerja dalam proses analisis sentimen. Tahapan penelitian meliputi:

1. Business Understanding

Tahap ini bertujuan untuk memahami permasalahan penelitian, yaitu bagaimana mengklasifikasikan sentimen ulasan pengguna aplikasi Grab dan Gojek di Google Play Store serta mengukur tingkat akurasi algoritma Support Vector Machine (SVM) dalam mengidentifikasi sentimen positif, negatif, dan netral.

2. Data Understanding

Pada tahap ini dilakukan pengumpulan dan eksplorasi data ulasan pengguna Grab dan Gojek dari Google Play Store dalam format CSV. Data dianalisis untuk mengetahui jumlah data, distribusi sentimen, serta memastikan tidak terdapat data duplikat atau kosong yang dapat mempengaruhi hasil analisis.

3. Data Preparation

Pada tahap ini, data ulasan mentah yang telah dikumpulkan diproses agar siap diolah oleh algoritma SVM. Proses ini dilakukan secara bertahap (*item per item*) untuk memastikan kualitas data. Tahapan *preprocessing* yang dilakukan adalah sebagai berikut:

a. Cleaning (Pembersihan Data): Membersihkan teks dari karakter yang tidak relevan seperti tanda baca, angka, *emoticon*, *username*, dan *link* URL yang dapat mengganggu analisis.

b. Case Folding: Mengubah seluruh huruf dalam teks menjadi huruf kecil (*lowercase*) untuk menyeragamkan data.

c. Tokenisasi (*Tokenizing*): Memecah kalimat menjadi potongan kata tunggal (*token*) yang berdiri sendiri.

d. Stopword Removal: Menghapus kata-kata umum (kata hubung) yang sering muncul namun tidak memiliki makna sentimen signifikan (seperti: "dan", "yang", "di").

e. Stemming: Mengubah kata berimbuhan menjadi kata dasar menggunakan algoritma Nazief & Adriani dari pustaka Sastrawi.

Berikut adalah tabel contoh perubahan data pada setiap tahapan *preprocessing*:

Tabel 3. 1 Contoh Hasil Preprocessing Data

Tahapan	Input Data	Output Data
Data Asli	"Drivernya nungguin lama banget & judes!!"	-
Cleaning	"Drivernya nungguin lama banget & judes!!"	"Drivernya nungguin lama banget judes"
Case Folding	"Drivernya nungguin lama banget judes"	"drivernya nungguin lama banget judes"
Tokenizing	"drivernya nungguin lama banget judes"	['drivernya', 'nungguin', 'lama', 'banget', 'judes']
Stopword	['drivernya', 'nungguin', 'lama', 'banget', 'judes']	['drivernya', 'nungguin', 'lama', 'judes']
Stemming	['drivernya', 'nungguin', 'lama', 'judes']	"driver tunggu lama judes"

Setelah melalui tahap *preprocessing*, dilakukan pelabelan data (*Labeling*) secara otomatis berdasarkan skor rating pengguna:

- **Sentimen Positif:** Rating bintang 4 dan 5.
- **Sentimen Netral:** Rating bintang 3.
- **Sentimen Negatif:** Rating bintang 1 dan 2.

Tahap terakhir adalah ekstraksi fitur menggunakan metode **TF-IDF** (*Term Frequency-Inverse Document Frequency*) untuk mengubah data teks menjadi vektor numerik yang dapat diproses oleh model SVM.

4. Modeling

Model klasifikasi dibangun menggunakan algoritma Support Vector Machine (SVM) dengan varian LinearSVC (Kernel Linear). Dataset dibagi

menjadi data latih (training set) dan data uji (testing set) dengan skenario pembagian 80:20. Model dilatih menggunakan data latih dan diuji menggunakan data uji untuk mengetahui performa klasifikasi.

5. Evaluation

Evaluasi model dilakukan menggunakan Confusion Matrix serta metrik evaluasi yang meliputi Accuracy, Precision, Recall, dan F1-Score untuk mengukur kinerja model dalam mengklasifikasikan sentimen secara akurat.

6. Deployment

Hasil analisis sentimen disajikan dalam bentuk laporan penelitian, grafik visualisasi (Pie Chart dan Wordcloud), serta tabel perbandingan performa untuk memberikan gambaran mengenai persepsi pengguna terhadap aplikasi Grab dan Gojek.

3.4 Alur Penelitian

Alur penelitian ini dirancang sebagai serangkaian tahapan sistematis yang terintegrasi untuk memastikan proses analisis sentimen pada ulasan aplikasi Grab dan Gojek berjalan sesuai dengan kaidah ilmiah yang ketat. Secara keseluruhan, metodologi penelitian ini mengadopsi standar Cross-Industry Standard Process for Data Mining (CRISP-DM), yang dimulai dari tahap paling awal yaitu identifikasi masalah serta studi literatur. Pada fase ini, dilakukan pemahaman mendalam mengenai dinamika layanan transportasi daring di Indonesia serta pengumpulan landasan teori mengenai keunggulan algoritma Support Vector Machine (SVM) dalam menangani data tekstual yang memiliki karakteristik dimensi fitur yang tinggi dan kompleks.


Setelah landasan teori terbentuk, langkah selanjutnya adalah pengumpulan data mentah melalui teknik web scraping langsung dari halaman produk Grab dan Gojek di Google Play Store. Proses ini dilakukan untuk menjaring ribuan ulasan pengguna yang mencakup isi komentar, rating bintang, hingga identitas waktu ulasan. Mengingat data yang

diperoleh dari interaksi digital umumnya bersifat tidak terstruktur dan mengandung banyak gangguan (noise), maka alur penelitian dilanjutkan ke tahap pra-pemrosesan teks yang sangat krusial. Tahapan ini mencakup cleansing untuk membersihkan simbol-simbol yang tidak relevan, case folding untuk penyeragaman huruf, hingga proses normalisasi kata menggunakan kamus slang untuk memperbaiki bahasa gaul yang sering digunakan oleh pengguna di Indonesia. Tidak berhenti di situ, proses filtering dilakukan untuk membuang kata-kata tugas yang tidak membawa makna sentimen, serta tahap stemming dengan bantuan library Sastrawi untuk mereduksi setiap kata menjadi bentuk dasarnya, sehingga konsistensi fitur dapat terjaga dengan baik.

Data yang telah bersih kemudian memasuki fase pelabelan, di mana setiap dokumen ulasan diberikan kategori sentimen positif atau negatif sebagai dasar pembelajaran mesin. Agar teks tersebut dapat dipahami oleh algoritma SVM, dilakukan ekstraksi fitur menggunakan metode Term Frequency-Inverse Document Frequency (TF-IDF). Metode ini akan menghitung bobot signifikansi setiap kata berdasarkan frekuensi kemunculannya terhadap keseluruhan dataset, sehingga informasi yang paling relevan bagi klasifikasi mendapatkan penekanan yang tepat. Masuk ke tahap inti eksperimen, data yang telah bertransformasi menjadi vektor numerik ini dibagi menjadi dua bagian, yaitu data latih untuk membangun kecerdasan model dan data uji untuk memvalidasi performanya. Algoritma SVM kemudian bekerja secara iteratif untuk mencari koordinat hyperplane atau bidang pemisah yang paling optimal dengan margin maksimal guna membedakan antara opini yang bernada positif dan negatif secara presisi.

Tahap akhir dari alur penelitian ini adalah proses evaluasi yang dilakukan secara komprehensif menggunakan instrumen Confusion Matrix. Melalui instrumen ini, peneliti dapat mengukur tingkat keberhasilan model melalui metrik Accuracy, Precision, Recall, dan F1-Score untuk memastikan bahwa hasil klasifikasi tidak hanya unggul di atas kertas, tetapi juga memiliki kemampuan generalisasi yang kuat terhadap data baru. Sebagai

penutup, seluruh hasil temuan divisualisasikan dalam bentuk grafik perbandingan serta analisis word cloud untuk mengidentifikasi kata kunci dominan yang mewakili keluhan maupun kepuasan pengguna. Penarikan kesimpulan dilakukan berdasarkan interpretasi data tersebut untuk memberikan jawaban atas rumusan masalah yang telah ditetapkan, sekaligus memberikan rekomendasi strategis bagi pengembangan layanan aplikasi di masa mendatang.



Gambar 3. 2 Alur Penelitian

BAB IV

IMPLEMENTASI

4.1 Business Understanding

Tahap *Business Understanding* merupakan fase awal yang paling krusial dalam metodologi CRISP-DM, di mana peneliti berfokus pada pemahaman terhadap tujuan dan kebutuhan dari sudut pandang bisnis atau operasional layanan. Pada tahap ini, penulis melakukan identifikasi mendalam dan merumuskan masalah utama yang menjadi fokus sentral dalam penelitian ini, yaitu tantangan dalam mengekstraksi informasi berharga dari jutaan ulasan pengguna aplikasi transportasi *online* yang tersedia secara publik.

Kesulitan utama muncul pada aspek analisis sentimen secara manual. Volume data ulasan yang sangat masif dan bertambah secara eksponensial setiap harinya membuat pemrosesan data oleh tenaga manusia menjadi tidak efisien, memakan waktu yang lama, serta memiliki tingkat subjektivitas yang tinggi. Padahal, ulasan pengguna di platform seperti Google Play Store mengandung aset informasi strategis mengenai tingkat kepuasan pelanggan, efektivitas fitur aplikasi, keluhan teknis yang terjadi secara *real-time*, hingga saran perbaikan kritis yang sering kali terlewatkan jika tidak diolah melalui sistem yang sistematis dan terotomatisasi.

Berdasarkan observasi lapangan dan analisis awal, terdapat kesenjangan antara kebijakan perusahaan transportasi *online* dengan realita pengalaman pengguna maupun mitra pengemudi. Ulasan-ulasan tersebut mencerminkan dinamika di lapangan yang sangat kompleks, mulai dari permasalahan tarif, ketepatan algoritma penjemputan, hingga kualitas layanan personal. Tantangan teknis yang dihadapi dalam mengolah data ini meliputi:

1. **Varietas Gaya Bahasa:** Pengguna cenderung menggunakan bahasa yang sangat informal dan ekspresif.
2. **Ambiguitas Linguistik:** Penggunaan singkatan yang tidak standar, kata tidak baku (*slang*), serta fenomena *code-mixing* (percampuran antara bahasa Indonesia dan Inggris) yang mempersulit mesin dalam memahami konteks sentimen yang sebenarnya.
3. **Karakteristik Data Teks:** Data teks yang bersifat tidak terstruktur (*unstructured data*) memerlukan penanganan khusus agar dapat dikonversi menjadi fitur numerik yang bermakna bagi algoritma pembelajaran mesin.

Maka dari itu, penelitian ini menerapkan algoritma Support Vector Machine (SVM) sebagai solusi teknis untuk melakukan klasifikasi sentimen pengguna aplikasi Grab dan Gojek ke dalam tiga kategori utama, yaitu sentimen positif, negatif, dan netral. Pemilihan SVM didasarkan pada ketangguhan algoritma ini dalam menangani data berdimensi tinggi dan kemampuannya dalam menciptakan optimal hyperplane untuk memisahkan kelas-kelas data dengan tingkat akurasi yang optimal.

Tujuan akhir dari tahap *Business Understanding* ini adalah untuk menyediakan sebuah model evaluasi layanan yang objektif dan terukur. Dengan adanya hasil klasifikasi sentimen yang akurat, perusahaan maupun pemangku kepentingan dapat memahami pola perilaku dan kebutuhan pengguna secara lebih mendalam, sehingga dapat diambil keputusan strategis guna meningkatkan loyalitas pelanggan serta memperbaiki kualitas layanan transportasi *online* secara berkelanjutan di Indonesia.

4.2 Data Understanding

Tahap *Data Understanding* merupakan fase di mana peneliti melakukan eksplorasi mendalam terhadap data yang telah dikumpulkan guna memahami karakteristik, struktur, serta potensi masalah yang ada pada data tersebut. Pada tahap ini, penulis melakukan proses pengumpulan data (*data*

acquisition) yang menjadi fondasi utama dalam eksperimen klasifikasi sentimen ini.

Data yang digunakan dalam penelitian ini adalah data sekunder berupa ulasan pengguna (*user reviews*) yang diambil secara publik dari platform Google Play Store. Pemilihan Google Play Store sebagai sumber data didasarkan pada fakta bahwa platform ini merupakan wadah utama bagi jutaan pengguna di Indonesia untuk memberikan umpan balik langsung terhadap performa aplikasi Grab dan Gojek. Proses pengambilan data dilakukan dengan menerapkan teknik Web Scraping secara otomatis.

Dalam pelaksanaannya, proses ekstraksi data dilakukan menggunakan bahasa pemrograman Python dengan bantuan pustaka (*library*) *google-play-scraper*. Pemilihan *library* ini didasarkan pada kemampuannya dalam melakukan *scraping* data dalam volume besar secara stabil tanpa memerlukan *API Key* yang kompleks, serta mendukung parameter bahasa (Indonesia) dan wilayah yang spesifik. Data yang berhasil ditarik mencakup beberapa atribut mentah yang kemudian dianalisis lebih lanjut, yaitu:

1. Username: Identitas unik pengguna yang memberikan ulasan. Meskipun tidak digunakan dalam proses klasifikasi, atribut ini penting untuk memastikan validitas bahwa ulasan berasal dari akun yang berbeda.
2. Isi Ulasan (*Content*): Merupakan data teks utama yang menjadi objek penelitian. Atribut ini berisi opini, keluhan, maupun apresiasi pengguna dalam bahasa alami yang nantinya akan diproses melalui tahapan NLP.
3. Rating (Skor Bintang 1-5): Atribut numerik yang memberikan gambaran awal mengenai tingkat kepuasan pengguna. Dalam tahap *Data Understanding* ini, *rating* digunakan sebagai acuan awal untuk menentukan label sentimen (misalnya: bintang 1-2 sebagai negatif, dan bintang 4-5 sebagai positif).
4. Tanggal Ulasan (*At*): Atribut waktu yang digunakan untuk membatasi rentang pengambilan data agar tetap relevan dengan kondisi layanan terkini dari kedua aplikasi tersebut.

Selain mengumpulkan atribut di atas, penulis juga melakukan audit kualitas data awal untuk melihat adanya data yang kosong (*missing values*) atau ulasan duplikat yang dapat mengganggu performa model SVM. Pada tahap ini, ditemukan bahwa dataset ulasan transportasi *online* memiliki karakteristik yang unik, yakni tingginya penggunaan bahasa non-formal dan simbol (seperti emoji).

Eksplorasi ini sangat penting untuk menentukan strategi Pre-processing pada tahap selanjutnya, karena peneliti harus memastikan bahwa data teks yang akan dimasukkan ke dalam model klasifikasi benar-benar merepresentasikan sentimen yang valid. Dengan memahami struktur data secara menyeluruh, peneliti dapat meminimalisir risiko kesalahan interpretasi algoritma terhadap dataset yang memiliki tingkat *noise* tinggi seperti ulasan di Google Play Store ini.

Tabel 4. 1 Sampel Dataset Hasil *Scraping*

ID	Aplikasi	Ulasan Teks	Rating
1	Grab	aplikasi rada rada nggak bener, masa tidak ada fitur cancel pesanan, seharusnya kalau tidak ada fitur cancel setidaknya dikasih waktu, ini pesanan saya sudah 1 jam nggak ada driver yang ngambil tetep aja jalan terus aplikasinya, dana ovo saya kegantung, mohon maaf bintangnya turun drastis dari 5 jadi 1, mohon maaf juga saya uninstall	1
2	Grab	tambah lama tambah aneh nih pelayanan grabcar, situasi jalan ga macet tapi diharuskan pake tol sama driver. kata supirnya klo ga mau pake tol harganya beda dan harus bayar langsung ke supirnya, dan yg di aplikasi harus di batalin. hadeehhh parah ..	2
3	Grab	aplikasi ojol termurah di kalangan pelajar.. sedikit cerita saya pelajar yang Nyambi kerja saya juga selalu mengalami kesulitan saat transportasi karena saya tidak memiliki sepeda motor tapi gpp tetap ada grab yang selalu di hati para pelajar murah, aman, nyaman, the Best... terimakasih	5
4	Gojek	Saya pesan makanan dengan estimasi yang terlambat sangat lama, mana tidak bisa di cancel, seharusnya ada opsi untuk pembeli gofood kalau waktu jauh melebihi estimasi bisa di cancel, atau setidaknya ada room chat buat pembeli dan pihak resto buat berpesan, terlambat hampir 1 jam! Kalo memang resto atau driver nggak bisa on time langsung beri info biar saya tidak menunggu lama !!!! Kalo memang tidak bisa setidaknya ngomong !!! Biar saya punya opsi cari di tempat lain !!!	1


5	Gojek	Makin kesini makin aneh, beda banget sama yang sebelah, bukan maksud bandingin, tapi pesen gofood jam 6 sama pesen shopeefood jam 6 lebih 40(18.40) yang datang cepet shopeefood, padahal lokasi gak terlalu jauh.	3
6	Gojek	aplikasi bagus banget dan kalau ada promo jadi murah banget sering" ada promo ya gojek ¹	5

Total data yang berhasil dikumpulkan sebanyak 3.990 data, yang terdiri dari 1.995 ulasan aplikasi Grab dan 1.995 ulasan aplikasi Gojek. Dataset ini kemudian disimpan dalam format .csv (Comma Separated Values) untuk memudahkan proses pengolahan selanjutnya..

Setelah dilakukan proses pengumpulan data, penulis melakukan analisis terhadap persebaran kelas sentimen pada dataset. Visualisasi total data sentimen dapat dilihat pada Gambar 4.1 dan Gambar 4.2 di bawah ini:

1. Analisis Sentimen Gojek

Berdasarkan hasil pengumpulan dan pelabelan data pada aplikasi Gojek, diperoleh distribusi sentimen sebagaimana ditunjukkan pada Gambar 4.1 berikut:




Gambar 4. 1 Distribusi Sentimen Ulasan Gojek

Dapat dilihat pada Gambar 4.1 bahwa dari total 1.995 data ulasan Gojek, sentimen negatif sangat mendominasi dengan jumlah 1.455 ulasan. Sementara itu, sentimen positif berjumlah 332 ulasan dan netral sebanyak 208 ulasan. Hal ini mengindikasikan bahwa selama periode pengambilan data, pengguna Gojek cenderung memberikan feedback terkait keluhan atau kendala layanan dibandingkan apresiasi.

2. Analisis Sentimen Grab

Sedangkan untuk aplikasi Grab, persebaran data ulasan dapat dilihat pada Gambar 4.2 di bawah ini:




Gambar 4. 2 Distribusi Sentimen Ulasan Grab

Pada aplikasi Grab, meskipun sentimen negatif tetap mendominasi (1.108 ulasan), namun jumlah sentimen positifnya (711 ulasan) terlihat lebih tinggi dibandingkan aplikasi Gojek. Sentimen netral berada pada angka 176 ulasan. Hal ini menunjukkan adanya perbedaan pola kepuasan pengguna antara kedua aplikasi pada dataset yang digunakan.

4.3 Data Preparation

Data yang telah dikumpulkan melalui proses crawling selanjutnya masuk ke dalam tahap persiapan (data preparation) agar dapat digunakan secara optimal dalam proses pelatihan model Support Vector Machine (SVM). Tahapan ini sangat krusial karena kualitas data mentah yang digunakan akan sangat memengaruhi performa akhir dari model klasifikasi yang dibangun. Pada tahap ini, dilakukan serangkaian proses preprocessing yang bertujuan untuk membersihkan noise, menangani data yang hilang (missing values), serta menstandarisasi format teks agar konsisten.


Proses pengolahan data ini seluruhnya dilakukan menggunakan platform Google Colaboratory. Penggunaan Google Colab memungkinkan penulis untuk memanfaatkan sumber daya komputasi berbasis cloud yang terintegrasi langsung dengan ekosistem Google Drive. Dengan menghubungkan direktori kerja ke Google Drive, dataset ulasan dapat diakses, dibaca, dan dimanipulasi secara efisien menggunakan pustaka Pandas dalam format CSV.



Gambar 4. 3 Dataset Ulasan Gojek yang Diakses pada Google Colab

Sebagaimana diperlihatkan pada Gambar 4.3, dataset ulasan Gojek yang tersimpan dalam repositori *cloud* dipanggil ke lingkungan kerja Google Colab untuk dilakukan inspeksi awal. Proses ini mencakup pemeriksaan struktur data dan verifikasi kolom-kolom kunci, seperti teks ulasan dan label rating, guna memastikan data termuat secara utuh tanpa ada kerusakan format.

Hal yang sama juga diterapkan pada dataset Grab sebagaimana ditunjukkan pada Gambar 4.4. Penulis memastikan konsistensi format antara kedua dataset tersebut agar tahapan *preprocessing* dapat dilakukan secara seragam. Dengan mengintegrasikan Google Drive, proses akses data menjadi lebih stabil dan efisien, sehingga mempermudah sinkronisasi dataset selama seluruh rangkaian eksperimen klasifikasi sentimen ini berlangsung.



Gambar 4. 4 Dataset Ulasan Grab yang Diakses pada Google Colab

Pemuatan dataset ini adalah langkah awal sebelum dilakukan transformasi data seperti *cleansing*, *folding*, *tokenizing*, dan ekstraksi fitur TF-IDF. Dengan memastikan dataset terunggah secara benar di Google Colab, proses sinkronisasi dan dokumentasi data selama eksperimen dapat berjalan lebih stabil dan teratur.

4.3.1 Preprocessing Teks

Tahapan *preprocessing* dilakukan untuk mengubah data teks mentah menjadi format yang lebih terstruktur. Proses ini meliputi:

- **Case Folding**
Mengubah seluruh huruf menjadi huruf kecil (*lowercase*) untuk menjaga konsistensi.
- **Cleaning**
Menghapus angka, tanda baca, *emoticon*, dan *link* URL menggunakan *Regular Expression* (Regex).
- **Tokenizing**
Memecah kalimat menjadi kata-kata tunggal (*token*).
- **Stopword Removal**
Menghapus kata hubung yang tidak bermakna sentimen (seperti "dan", "yang", "di") menggunakan pustaka Sastrawi.
- **Stemming**
Mengubah kata berimbuhan menjadi kata dasar (contoh: "pelayanan" menjadi "layan") menggunakan algoritma Nazief & Adriani dari pustaka Sastrawi.

Tabel 4. 2 Contoh Hasil Preprocessing

No	Teks Asli	Hasil Preprocessing
1	"Aplikasi Grab error mulu nih, tolong diperbaiki!!!"	"aplikasi grab error tolong baik"
2	"Gojek sangat mantap... driver ramah banget bintang 5"	"gojek mantap driver ramah bintang"
3	"Kecewa berat, harga mahal banget skrg gak kayak dulu :("	"kecewa berat harga mahal sekarang tidak"
4	"Sering banget dapet driver yang mobilnya bau rokok."	"sering dapat driver mobil bau rokok"
5	"Fitur chat-nya lemot, pesen makan nunggu 2 jam baru sampe."	"fitur chat lemot pesan makan tunggu jam sampai"

Berdasarkan tabel di atas, proses preprocessing berhasil membersihkan karakter tidak relevan, melakukan stemming, serta menghapus stopwords sehingga data siap diproses oleh algoritma.

4.3.2 Pelabelan Sentimen

Pelabelan dilakukan secara otomatis menggunakan pendekatan berbasis rating (rating-based labeling). Hal ini dilakukan untuk menghindari bias subjektivitas peneliti. Aturan pelabelan adalah sebagai berikut:

Positif: Ulasan dengan rating bintang 4 dan 5.

Netral: Ulasan dengan rating bintang 3.

Negatif: Ulasan dengan rating bintang 1 dan 2.

Label ini kemudian digunakan sebagai target (y) dalam proses klasifikasi supervised learning.

Setelah preprocessing, data ulasan diberi label sentimen secara otomatis menggunakan pendekatan lexicon-based. Pelabelan ini mengelompokkan ulasan ke dalam tiga kategori sentimen, yaitu positif, negatif, dan netral. Label ini kemudian digunakan sebagai target (y) dalam proses klasifikasi.

4.3.3 Pembobotan Kata (TF-IDF)

Setelah teks bersih, data dikonversi menjadi vektor numerik menggunakan metode Term Frequency-Inverse Document Frequency (TF-IDF). Metode ini memberikan bobot lebih tinggi pada kata yang unik dan spesifik, serta bobot rendah pada kata yang terlalu umum muncul di semua dokumen.


(1) Pembagian Dataset (*Splitting*)

Dataset dibagi menjadi dua bagian dengan proporsi 80:20, yaitu 80% sebagai data latih (training set) untuk melatih model, dan 20% sebagai data uji (testing set) untuk mengevaluasi performa model.

- Total Data: 3.990 data.
- Data Latih (80%): 3.192 data.
- Data Uji (20%): 798 data.

Tahapan penting dalam pembangunan model klasifikasi adalah pembagian dataset menjadi dua bagian yang berbeda fungsionalitasnya. Proses pembagian dataset ini dilakukan secara acak menggunakan fungsi `train_test_split` dari pustaka Scikit-Learn dengan menetapkan parameter `test_size=0.20`. Hal ini berarti 80% data dialokasikan untuk melatih algoritma agar mampu mengenali pola sentimen, sementara 20% sisanya dipertahankan sebagai data uji yang berfungsi sebagai instrumen evaluasi performa model secara objektif.

Khusus untuk dataset aplikasi Gojek, distribusi frekuensi jumlah data latih dan data uji setelah melalui tahap persiapan data dapat dilihat secara detail pada visualisasi Gambar 4.5 berikut:




Gambar 4. 5 Visualisasi Pembagian Data Latih dan Data Uji Gojek

Berdasarkan Gambar 4.5, terlihat bahwa dataset Gojek memiliki 3.492 data latih dan 873 data uji. Jumlah data latih yang besar sangat penting agar algoritma SVM dapat mengenali berbagai variasi pola kata sentimen dengan lebih akurat.

Selanjutnya, konsistensi dalam metodologi penelitian dijaga dengan menerapkan prosedur pembagian dataset yang identik pada aplikasi Grab. Menggunakan proporsi yang sama, yaitu 80% untuk data latih dan 20% untuk data uji, proses splitting ini dijalankan secara komputasi untuk memastikan model memiliki data evaluasi yang tidak bias. Langkah ini sangat krusial dalam algoritma Machine Learning seperti SVM untuk menjamin bahwa tingkat akurasi yang dihasilkan nantinya merupakan representasi objektif dari kemampuan model dalam mengklasifikasi ulasan baru.

Visualisasi mengenai distribusi frekuensi serta perbandingan jumlah data latih dan data uji untuk dataset aplikasi Grab dapat dilihat pada Gambar 4.6 berikut:



Gambar 4. 6 Visualisasi Pembagian Data Latih dan Data Uji Grab

Pada dataset Grab, terdapat 2.659 data latih dan 665 data uji. Perbedaan total angka dengan Gojek dikarenakan proses pembersihan data yang menghasilkan jumlah baris ulasan yang berbeda setelah tahap preprocessing.

4.4 Modeling (Implementasi SVM)

Tahap evaluasi dilakukan untuk mengukur performa model SVM (LinearSVC) menggunakan data uji sebesar 20% dari total dataset dengan metrik accuracy, precision, recall, F1-score, dan confusion matrix.

1. Hasil Evaluasi Model Gojek

Berdasarkan pengujian, model memperoleh akurasi sebesar **96%**, menunjukkan kemampuan klasifikasi yang sangat baik. Confusion matrix menunjukkan sebagian besar data diprediksi dengan benar dengan kesalahan yang relatif kecil, serta nilai precision, recall, dan F1-score yang tinggi pada setiap kelas.


```
from sklearn.metrics import confusion_matrix
import seaborn as sns
import numpy as np

cm = confusion_matrix(y_test, y_pred)

plt.figure()
sns.heatmap(cm,
            annot=True,
            fmt='d',
            xticklabels=np.unique(y_test),
            yticklabels=np.unique(y_test))

plt.title("SVM Confusion Matrix")
plt.xlabel("Predicted")
plt.ylabel("Actual")

plt.show()
```



Gambar 4. 7 Evaluasi Gojek

2. Hasil Evaluasi Model Grab


Pada dataset ulasan aplikasi Grab, model SVM memperoleh akurasi sebesar 91%, yang menunjukkan kemampuan klasifikasi sentimen yang sangat baik. Nilai precision, recall, dan F1-score juga menunjukkan performa yang baik dan seimbang pada setiap kelas sentimen.

```
from sklearn.metrics import confusion_matrix
import seaborn as sns
import numpy as np

cm = confusion_matrix(y_test, y_pred)

plt.figure()
sns.heatmap(cm,
            annot=True,
            fmt='d',
            xticklabels=np.unique(y_test),
            yticklabels=np.unique(y_test))

plt.title("SVM Confusion Matrix")
plt.xlabel("Predicted")
plt.ylabel("Actual")
plt.show()
```



Gambar 4. 8 Evaluasi Grab

3. Analisis Perbandingan

Jika dilakukan perbandingan secara mendalam, model klasifikasi pada dataset Gojek menghasilkan tingkat akurasi yang sedikit lebih unggul, yakni sebesar 96%, jika dibandingkan dengan dataset Grab yang memperoleh akurasi sebesar 91%. Selisih akurasi ini tidak hanya dipengaruhi oleh kuantitas data, tetapi juga dipengaruhi oleh distribusi kelas sentimen yang lebih seimbang serta karakteristik ulasan pengguna yang cenderung lebih spesifik. Tingkat konsistensi penggunaan kosakata dan minimnya variasi *noise* pada dataset Gojek memungkinkan model untuk mengenali pola fitur teks secara lebih optimal dibandingkan pada dataset Grab yang mungkin memiliki keberagaman bahasa yang lebih luas.

Secara keseluruhan, hasil evaluasi komprehensif ini menegaskan bahwa implementasi algoritma *Support Vector Machine* (khususnya menggunakan *LinearSVC*) yang dikombinasikan dengan metode ekstraksi fitur TF-IDF mampu memberikan performa klasifikasi sentimen yang sangat reliabel pada ulasan aplikasi transportasi daring. Keberhasilan model dalam mencapai angka di atas 90% menunjukkan bahwa metode ini sangat efektif dalam menangani data teks tidak terstruktur yang mengandung banyak bahasa gaul (*slang*), singkatan, maupun ketidakteraturan sintaksis. Hal ini sekaligus memvalidasi bahwa pemilihan kernel linear dan pembobotan kata berbasis frekuensi merupakan pendekatan yang tepat untuk menghasilkan generalisasi model yang akurat dalam studi kasus ini.

4.5 Evaluasi Model

Setelah tahap pelatihan model selesai dilakukan, langkah berikutnya adalah melakukan pengujian menggunakan data uji (*testing set*) yang belum pernah dilihat oleh model sebelumnya. Tahap evaluasi ini bertujuan untuk mengukur sejauh mana model *Support Vector Machine* (SVM) mampu melakukan generalisasi terhadap data baru dengan akurat. Evaluasi dilakukan secara komprehensif menggunakan instrumen *Confusion Matrix* untuk menghasilkan metrik penilaian berupa *Accuracy*, *Precision*, *Recall*, dan *F1-Score*.

```
best_model = grid.best_estimator_  
y_pred = best_model.predict(x_test)  
print("Akurasi:", accuracy_score(y_test, y_pred))  
print(classification_report(y_test, y_pred))
```

```
... Akurasi: 0.9621993127147767  
      precision    recall  f1-score   support  
  
   negatif      0.99      0.90      0.94        291  
    netral      0.94      0.99      0.97        291  
   positif      0.96      1.00      0.98        291  
  
   accuracy              0.96        873  
  macro avg      0.96      0.96      0.96        873  
 weighted avg      0.96      0.96      0.96        873
```

Gambar 4. 9 Evaluasi Model Gojek

```
best_model = grid.best_estimator_  
y_pred = best_model.predict(x_test)  
print("Akurasi:", accuracy_score(y_test, y_pred))  
print(classification_report(y_test, y_pred))
```

```
... Akurasi: 0.9112781954887218  
      precision    recall  f1-score   support  
  
   negatif      0.91      0.83      0.87        221  
    netral      0.94      1.00      0.97        222  
   positif      0.88      0.91      0.89        222  
  
   accuracy              0.91        665  
  macro avg      0.91      0.91      0.91        665  
 weighted avg      0.91      0.91      0.91        665
```

Gambar 4. 10 Evaluasi Model Grab

Pada potongan kode di atas, implementasi evaluasi dimulai dengan menginisialisasi algoritma *LinearSVC* dari pustaka *Scikit-Learn*. Penggunaan parameter `random_state=42` menjadi sangat penting untuk menjamin konsistensi hasil eksperimen (*reproducibility*), sehingga nilai akurasi yang dihasilkan akan tetap sama setiap kali kode dijalankan ulang.

Selanjutnya, model dilatih menggunakan fungsi `.fit()` pada data latih (*training set*) yang sebelumnya telah melalui proses penyeimbangan kelas menggunakan SMOTE dan ekstraksi fitur TF-IDF.

Setelah proses *training* dinyatakan selesai dan model telah terbentuk, dilakukan proses prediksi terhadap data uji menggunakan fungsi `.predict()`. Hasil prediksi tersebut kemudian dibandingkan dengan label aktual untuk melihat seberapa besar penyimpangan atau kesalahan klasifikasi yang terjadi melalui fungsi `classification_report`

4.5.1 Analisis Hasil Klasifikasi

Berdasarkan hasil eksekusi program pada Gambar 4.9 dan Gambar 4.10, diperoleh gambaran performa model yang sangat signifikan untuk kedua dataset. Analisis terhadap hasil tersebut mencakup beberapa poin utama:

1. **Stabilitas Performa:** Model menunjukkan nilai yang seimbang antara Precision dan Recall pada masing-masing kelas (positif, negatif, dan netral). Hal ini mengindikasikan bahwa penggunaan SMOTE efektif dalam mengatasi kendala imbalanced data yang sering terjadi pada ulasan aplikasi.
2. **Akurasi Keseluruhan:** Terlihat bahwa model mampu mengenali pola sentimen pengguna dengan tingkat akurasi yang tinggi. Hal ini membuktikan bahwa penggunaan kernel linear pada SVM sangat cocok untuk menangani data teks dengan dimensi tinggi hasil dari pembobotan TF-IDF.
3. **Identifikasi Noise:** Meskipun terdapat penggunaan bahasa gaul dan singkatan tidak standar dalam ulasan Grab dan Gojek, model tetap mampu mengklasifikasikan sentimen dengan tepat. Ini menunjukkan bahwa tahap preprocessing yang dilakukan sebelumnya telah berhasil menstandarisasi fitur teks sehingga dapat dipelajari dengan baik oleh algoritma LinearSVC.

4.5.2 Analisis Konten Sentimen (Wordcloud)

Analisis konten dilakukan untuk mengetahui kata-kata yang paling sering muncul dan merepresentasikan opini pengguna terhadap layanan Grab dan Gojek. Visualisasi menggunakan *Wordcloud* membantu dalam mengidentifikasi kata kunci dominan pada setiap kelas sentimen.

1. Analisis Wordcloud Sentimen Positif Grab

Untuk memberikan gambaran mengenai kata-kata yang paling berpengaruh dalam klasifikasi sentimen positif pada aplikasi **Grab**, dilakukan visualisasi menggunakan *Wordcloud* sebagaimana ditunjukkan pada Gambar 4.11 berikut:



Gambar 4. 11 Wordcloud Sentimen Positif Grab

Berdasarkan visualisasi *Wordcloud* pada Gambar 4.11, terlihat bahwa kata '**cepat**', '**mudah**', dan '**bagus**' tampil dengan ukuran yang paling dominan. Hal ini menunjukkan frekuensi kemunculan kata-kata tersebut sangat tinggi dalam dataset ulasan positif aplikasi Grab, di mana ukuran kata dalam *Wordcloud* berbanding lurus dengan jumlah kemunculannya.

Temuan ini membuktikan bahwa aspek efisiensi layanan, seperti kecepatan respon dan kemudahan penggunaan aplikasi, merupakan faktor utama yang melandasi kepuasan pengguna Grab. Dominasi kata kunci

tersebut mencerminkan bahwa performa operasional dan fungsionalitas sistem yang handal memberikan pengalaman pengguna yang positif, sehingga menjadi elemen kunci dalam membangun sentimen positif pada platform Grab selama periode penelitian.

2. Analisis Wordcloud Gojek

Sementara itu, visualisasi Wordcloud untuk sentimen positif pada aplikasi Gojek ditunjukkan pada Gambar 4.12 di bawah ini:



Gambar 4. 12 Wordcloud Sentimen Positif Gojek

Sementara itu, pada visualisasi Wordcloud untuk aplikasi Gojek sebagaimana ditampilkan pada Gambar 4.12, kata 'cepat' kembali muncul sebagai kata yang paling menonjol secara visual. Tren ini kemudian diikuti secara signifikan oleh kemunculan kata 'bagus', 'mudah', dan 'ramah' dengan intensitas frekuensi yang tinggi.

Munculnya kata 'ramah' dan 'aman' dalam ukuran yang cukup besar pada dataset Gojek memberikan temuan menarik, di mana aspek interpersonal atau perilaku mitra pengemudi (driver) memberikan impresi positif yang kuat bagi para pengguna. Hal ini mengindikasikan bahwa kualitas pelayanan secara langsung (tatap muka) menjadi salah satu

keunggulan kompetitif yang dirasakan pengguna selain fitur fungsional aplikasi itu sendiri. Secara keseluruhan, kombinasi kata kunci ini mencerminkan bahwa kepuasan pengguna Gojek dalam penelitian ini dipengaruhi oleh harmonisasi antara performa sistem yang responsif serta kualitas etika pelayanan dari mitra pengemudi di lapangan.

3. Analisis Wordcloud Negatif Grab

Selain menganalisis kesan positif, penelitian ini juga memetakan keluhan utama pengguna melalui visualisasi Wordcloud sentimen negatif. Untuk aplikasi Grab, hasil visualisasi kata yang sering muncul dapat dilihat pada Gambar 4.13 berikut:



Gambar 4. 13 Wordcloud Sentimen Negatif Grab

Berdasarkan visualisasi Wordcloud sentimen negatif pada Gambar 4.13 terlihat secara eksplisit bahwa kata 'mahal' muncul dengan ukuran font yang paling dominan di antara kata-kata lainnya. Hal ini merepresentasikan bahwa isu terkait tarif atau biaya layanan merupakan sumber ketidakpuasan utama dan paling krusial bagi pengguna Grab dalam dataset penelitian ini.

Munculnya kata-kata pendukung seperti 'error', 'kecewa', dan 'lelet' dengan intensitas yang cukup tinggi mempertegas adanya kendala teknis serta penurunan performa aplikasi yang dirasakan langsung oleh pengguna. Keluhan yang berpusat pada aspek harga dan kehandalan sistem ini mengindikasikan bahwa ekspektasi pengguna terhadap kesesuaian harga

layanan dengan kenyamanan akses aplikasi belum sepenuhnya terpenuhi secara optimal. Secara keseluruhan, temuan ini memberikan gambaran bahwa sentimen negatif pengguna Grab sangat dipengaruhi oleh sensitivitas harga serta pengalaman buruk terkait stabilitas sistem pada platform tersebut.

4. Analisis Wordcloud Negatif Gojek

Perbandingan dilakukan dengan melihat kecenderungan keluhan pada aplikasi Gojek yang disajikan pada Gambar 4.14 di bawah ini:



Gambar 4. 14 Wordcloud Sentimen Negatif Gojek

Berdasarkan visualisasi pada Gambar 4.14, sentimen negatif pengguna Gojek didominasi oleh keluhan terkait tarif ('mahal') dan stabilitas sistem ('error'). Selain itu, munculnya kata 'lelet' dan 'lambat' mengonfirmasi adanya kendala pada performa aplikasi maupun durasi tunggu layanan. Temuan menarik lainnya adalah kemunculan kata 'kasar' yang mengindikasikan keluhan spesifik terhadap etika pelayanan mitra. Secara keseluruhan, ulasan negatif ini menunjukkan bahwa selain masalah teknis dan harga, kualitas interaksi antara mitra dan pelanggan tetap menjadi variabel penting yang memengaruhi persepsi pengguna terhadap platform Gojek.

BAB V

HASIL DAN PEMBAHASAN

5.1 Evaluasi Model

Setelah melalui tahapan pengembangan model menggunakan algoritma *Support Vector Machine* (SVM), langkah selanjutnya adalah melakukan evaluasi performa guna mengukur sejauh mana model mampu melakukan generalisasi terhadap data yang belum pernah dilihat sebelumnya. Dalam penelitian ini, pengujian dilakukan dengan menerapkan skema pembagian data (*data splitting*) menggunakan proporsi **80% untuk data latih (*training data*)** dan **20% untuk data uji (*testing data*)**. Penggunaan data latih sebesar 80% bertujuan agar model SVM memiliki basis pengetahuan yang cukup luas untuk mengenali berbagai pola kata dan karakteristik sentimen, sementara 20% data uji digunakan sebagai instrumen validasi objektif untuk mengukur akurasi prediksi.

Evaluasi ini difokuskan pada kemampuan model dalam menentukan *hyperplane* pemisah yang optimal antar kelas sentimen (positif, negatif, dan netral). Untuk mendapatkan gambaran performa yang komprehensif, pengukuran kinerja tidak hanya terpaku pada angka akurasi semata, melainkan menggunakan **Confusion Matrix** sebagai alat analisis utama. *Confusion Matrix* memungkinkan peneliti untuk melihat distribusi klasifikasi yang benar (*True Positive* dan *True Negative*) serta mengidentifikasi adanya kesalahan klasifikasi (*False Positive* dan *False Negative*) pada masing-masing label sentimen.

Selanjutnya, hasil dari *Confusion Matrix* tersebut ditransformasikan ke dalam **Classification Report** untuk menghitung metrik evaluasi yang lebih spesifik, yaitu:

- **Accuracy:** Menggambarkan persentase total prediksi yang benar (baik positif, negatif, maupun netral) dari keseluruhan data uji.
- **Precision:** Mengukur tingkat keakuratan model dalam memberikan label pada suatu kelas tertentu; sangat penting untuk meminimalisir kesalahan klasifikasi (misalnya, ulasan negatif yang terdeteksi sebagai positif).
- **Recall (Sensitivity):** Mengukur kemampuan model dalam menemukan kembali seluruh informasi dari suatu kelas; memastikan tidak banyak ulasan yang terlewatkan dari kategori yang seharusnya.
- **F1-Score:** Merupakan nilai rata-rata harmonik antara *Precision* dan *Recall*, yang memberikan gambaran performa model secara seimbang, terutama jika terdapat ketidakseimbangan jumlah data antar kelas (*imbalanced data*).

Melalui kombinasi metrik-metrik tersebut, peneliti dapat memvalidasi apakah model SVM yang dibangun telah mencapai performa yang handal dan stabil dalam menganalisis dinamika opini pengguna pada aplikasi Grab dan Gojek.

5.1.1 Confusion Matrix

Setelah model *Support Vector Machine* (SVM) selesai melalui tahap pengujian menggunakan data uji, hasil klasifikasi tersebut dianalisis lebih lanjut menggunakan **Confusion Matrix**. *Confusion Matrix* merupakan alat evaluasi berupa tabel kontingensi yang digunakan untuk memvisualisasikan performa algoritma klasifikasi secara spesifik dengan cara membandingkan label hasil prediksi model terhadap label sebenarnya (*ground truth*) yang ada pada dataset.

Penggunaan *Confusion Matrix* sangat krusial dalam penelitian ini karena memberikan informasi yang lebih mendalam dibandingkan sekadar angka akurasi tunggal. Melalui matriks ini, peneliti dapat mengidentifikasi secara detail pada kelas mana model SVM mengalami kesulitan. Matriks ini terdiri dari empat komponen utama yang merepresentasikan hasil klasifikasi, yaitu:

1. **True Positive (TP):** Jumlah data ulasan yang diprediksi benar sesuai dengan kelas aslinya.
2. **True Negative (TN):** Jumlah data ulasan yang diprediksi benar bukan merupakan bagian dari kelas tersebut.
3. **False Positive (FP):** Kasus di mana model salah memprediksi suatu ulasan ke dalam kelas tertentu (misalnya ulasan negatif yang diprediksi sebagai positif).
4. **False Negative (FN):** Kasus di mana model gagal mengenali ulasan yang seharusnya masuk ke dalam kelas tersebut.

Dalam konteks klasifikasi tiga kelas (*multiclass*) yang digunakan dalam penelitian ini (Positif, Negatif, dan Netral), *Confusion Matrix* menampilkan distribusi prediksi untuk masing-masing kategori tersebut. Hal ini memungkinkan peneliti untuk melihat pola kesalahan model, misalnya apakah model sering tertukar dalam membedakan antara sentimen Netral dan Negatif. Visualisasi ini menjadi landasan utama bagi peneliti untuk menghitung metrik performa lainnya seperti *Precision*, *Recall*, dan *F1-Score*.

5.1.2 Classification Report

Tahap evaluasi selanjutnya dilakukan dengan membedah hasil klasifikasi ke dalam Classification Report. Laporan ini merupakan instrumen penting untuk memvalidasi performa model Support Vector Machine (SVM) secara granular, melampaui angka akurasi global. Dengan memecah performa ke dalam metrik Precision, Recall, dan F1-Score, kita dapat memahami perilaku model terhadap karakteristik unik dari masing-masing kelas sentimen (Positif, Negatif, dan Netral). Berikut adalah detail performa model berdasarkan pengujian pada 798 data uji, yang merupakan 20% dari keseluruhan dataset yang telah diproses:

...	Akurasi: 0.9621993127147767				
		precision	recall	f1-score	support
	negatif	0.99	0.90	0.94	291
	netral	0.94	0.99	0.97	291
	positif	0.96	1.00	0.98	291
	accuracy			0.96	873
	macro avg	0.96	0.96	0.96	873
	weighted avg	0.96	0.96	0.96	873

Gambar 5. 1 Hasil Laporan Klasifikasi (*Classification Report*) Gojek

```

... Akurasi: 0.9112781954887218
      precision    recall  f1-score   support

negatif    0.91     0.83     0.87     221
netral     0.94     1.00     0.97     222
positif    0.88     0.91     0.89     222

accuracy    0.91     0.91     0.91     665
macro avg   0.91     0.91     0.91     665
weighted avg 0.91     0.91     0.91     665

```

Gambar 5. 2 Hasil Laporan Klasifikasi (*Classification Report*) Grab

Hasil evaluasi secara menyeluruh menunjukkan bahwa model SVM yang telah dibangun memiliki tingkat Akurasi sebesar 0.91 atau 91% dari total 665 ulasan yang diuji. Pencapaian angka di atas 90% ini mengindikasikan bahwa proses preprocessing dan ekstraksi fitur TF-IDF yang dilakukan sebelumnya telah berhasil menyajikan informasi yang sangat diskriminatif bagi algoritma SVM untuk membentuk hyperplane yang optimal.

Berikut adalah analisis mendalam mengenai performa pada tiap-tiap kelas sentimen:

Analisis Kelas Netral: Kategori ini mencatatkan performa yang paling dominan dengan nilai F1-Score sebesar 0.97 dan Recall mencapai angka sempurna (1.00). Nilai Recall 1.00 ini secara teknis membuktikan bahwa tidak ada ulasan netral yang terlewatkan oleh model; semua data yang secara faktual berlabel netral berhasil diklasifikasikan dengan tepat. Hal ini menunjukkan bahwa pola bahasa pada ulasan netral, yang biasanya bersifat informatif atau pasif, memiliki struktur yang sangat konsisten sehingga sangat mudah dikenali oleh model SVM.

Analisis Kelas Positif: Pada kelas positif, model menghasilkan Precision sebesar 0.88, Recall 0.91, dan F1-Score 0.89. Tingginya nilai Recall dibandingkan Precision pada kelas ini menunjukkan bahwa model cenderung lebih 'berani' dalam mengelompokkan ulasan ke dalam kategori positif. Meskipun terdapat sedikit ulasan dari kelas lain yang ikut terprediksi sebagai positif (False Positive), secara keseluruhan model tetap sangat konsisten dalam mengidentifikasi ekspresi kepuasan pengguna terhadap layanan Grab dan Gojek.

Analisis Kelas Negatif: Kelas negatif memperoleh Precision sebesar 0.91, Recall 0.83, dan F1-Score 0.87. Meskipun angka ini sudah tergolong sangat baik (di atas standar industri 0.80), nilai Recall yang paling rendah di antara kelas lainnya memberikan catatan evaluasi yang menarik. Hal ini mengindikasikan bahwa sekitar 17% ulasan yang sebenarnya mengandung sentimen negatif gagal terdeteksi oleh model dan justru masuk ke kelas lain. Secara linguistik, hal ini sering terjadi karena ulasan negatif terkadang menggunakan gaya bahasa sarkasme atau kosakata yang ambigu yang mirip dengan ulasan netral. Namun, nilai Precision yang tinggi (0.91) memastikan bahwa jika model sudah memberikan label negatif, maka kemungkinan besar prediksi tersebut benar-benar akurat.

Secara kolektif, nilai Macro Average dan Weighted Average yang konsisten di angka 0.91 menegaskan bahwa model ini stabil dan tidak bias terhadap satu kelas tertentu saja (robust). Performa yang seimbang ini menunjukkan bahwa algoritma SVM sangat handal dalam menangani kompleksitas opini pelanggan pada platform transportasi online, di mana perbedaan tipis antar kata-kata dalam ulasan dapat menentukan perbedaan label sentimen secara signifikan.

5.2 Analisis Kinerja Algoritma dan Komparasi Literatur

Hasil pengujian komprehensif dalam penelitian ini membuktikan bahwa algoritma Support Vector Machine (SVM) memiliki efikasi yang sangat tinggi dalam melakukan tugas klasifikasi sentimen pada platform transportasi online. Capaian akurasi sebesar 91% pada data Grab dan 96% pada data Gojek menunjukkan konsistensi algoritma ini dalam melakukan generalisasi data. Tingginya angka akurasi ini bukan merupakan suatu kebetulan, melainkan hasil dari keunggulan matematis SVM yang menerapkan prinsip Structural Risk Minimization (SRM). Melalui prinsip ini, SVM tidak hanya meminimalisir kesalahan pada data latih (empirical risk), tetapi juga mampu membangun optimal hyperplane yang memisahkan kelas sentimen (positif, negatif, dan netral) berdasarkan margin maksimal, sehingga model tetap tangguh saat dihadapkan pada data uji yang belum pernah dilihat sebelumnya.

Kemampuan SVM dalam menavigasi data ulasan yang memiliki dimensi fitur tinggi (high-dimensional data) sebagai implikasi dari teknik pembobotan TF-IDF terbukti jauh lebih stabil dibandingkan dengan banyak algoritma klasifikasi lainnya. Ketika ulasan teks ditransformasikan menjadi ribuan vektor fitur, SVM mampu menentukan batas keputusan tanpa terjebak dalam masalah curse of dimensionality. Temuan ini selaras dengan studi literatur yang dilakukan oleh (Wiguna et al., 2023), yang melakukan eksperimen perbandingan performa berbagai algoritma pada dataset transportasi online. Dalam studi tersebut, terungkap bahwa algoritma Naive Bayes hanya mampu mencapai akurasi sebesar 77%, sementara SVM secara signifikan melampauinya dengan capaian akurasi mencapai 90%. Perbedaan yang mencolok ini menegaskan bahwa SVM jauh lebih unggul dalam memetakan pola bahasa yang kompleks dan beragam.

Keunggulan signifikan SVM dibandingkan Naive Bayes terletak pada perbedaan fundamental filosofi komputasinya. Naive Bayes bekerja dengan asumsi independensi yang sangat kuat (bahwa setiap kata berdiri sendiri), padahal ulasan pada Google Play Store seringkali mengandung frasa atau rangkaian kata yang saling berkaitan secara kontekstual untuk membentuk suatu makna sentimen. Sebaliknya, SVM bekerja dengan mencari titik-titik support vectors yang paling kritis untuk menentukan batas kelas, sehingga hubungan antar fitur tetap terjaga dalam ruang dimensi tinggi. Hal ini terbukti efektif dalam meminimalisir kesalahan klasifikasi yang sering terjadi pada metode berbasis probabilitas, yang cenderung gagal ketika menghadapi kata-kata ambigu atau kalimat yang memiliki ketergantungan antar kata yang kuat.

Lebih lanjut, penggunaan kernel linear dalam penelitian ini juga memberikan efisiensi komputasi yang optimal tanpa mengorbankan akurasi. Dengan demikian, pemilihan SVM sebagai metode klasifikasi bukan hanya sekadar mengikuti tren literatur, melainkan sebuah keputusan teknis yang tepat untuk menjawab tantangan data ulasan yang bersifat tidak terstruktur, penuh dengan slang, dan memiliki variasi bahasa yang sangat beragam.

Hasil ini memperkuat posisi SVM sebagai salah satu algoritma paling reliabel dalam tugas Natural Language Processing (NLP) untuk ulasan pelanggan di industri layanan digital Indonesia

5.3 Analisis Komparatif (Grab vs Gojek)

Penelitian ini melakukan analisis komparatif untuk membandingkan performa algoritma *Support Vector Machine* (SVM) pada dua dataset yang berbeda, yaitu ulasan aplikasi Grab dan Gojek. Tujuan dari analisis ini adalah untuk menguji konsistensi serta ketangguhan (*robustness*) model terhadap variasi karakteristik data, gaya bahasa, dan pola opini yang diberikan oleh pengguna pada kedua platform transportasi *online* terbesar di Indonesia tersebut.

Tabel 5. 1 Perbandingan Akurasi Model

No	Objek Aplikasi	Jumlah Data Uji	Akurasi
1	Gojek	399	96%
2	Grab	399	91%

Berdasarkan hasil pengujian yang dipaparkan pada Tabel 5.1, model SVM menunjukkan performa yang sangat impresif pada kedua dataset. Namun, terdapat perbedaan capaian akurasi di mana dataset Gojek menghasilkan akurasi sebesar 96%, lebih tinggi dibandingkan dataset Grab yang mencapai 91%. Meskipun terdapat selisih akurasi sebesar 5%, kedua hasil ini tetap berada pada kategori performa "Sangat Baik" karena konsisten berada di atas ambang batas 90%.

Perbedaan selisih 5% tersebut memberikan indikasi adanya perbedaan karakteristik linguistik antara kedua dataset. Akurasi yang lebih tinggi pada Gojek (96%) menunjukkan bahwa pola ulasan pengguna Gojek cenderung lebih konsisten dan memiliki kata kunci yang lebih eksplisit dalam membedakan antara sentimen positif, negatif, dan netral. Hal ini memudahkan *hyperplane* SVM untuk menentukan batas keputusan yang lebih tegas dengan margin yang luas.

Di sisi lain, akurasi 91% pada dataset Grab menunjukkan adanya variasi bahasa yang sedikit lebih kompleks. Hal ini bisa disebabkan oleh penggunaan kosakata yang lebih beragam, adanya campuran bahasa (kode-switching), atau ulasan yang mengandung ambiguitas tinggi, sehingga terdapat titik-titik data yang berada sangat dekat dengan batas keputusan (*decision boundary*). Fenomena ini menyebabkan model harus bekerja lebih ekstra dalam mengidentifikasi *support vectors* yang tepat agar tidak terjadi kesalahan klasifikasi.

Namun demikian, secara keseluruhan, hasil komparasi ini membuktikan bahwa algoritma SVM memiliki stabilitas yang sangat baik. Kemampuannya untuk tetap menghasilkan akurasi di atas 90% pada dua objek penelitian yang berbeda menunjukkan bahwa model ini tidak hanya pintar dalam mengenali satu jenis data saja, tetapi juga handal dalam menangani dinamika ulasan pelanggan di industri transportasi *online* secara umum. Stabilitas ini menjadi bukti bahwa implementasi SVM dengan pembobotan TF-IDF adalah solusi yang sangat efektif untuk tugas klasifikasi sentimen berskala besar.

5.4 Deployment

Tahap deployment merupakan fase krusial untuk memvalidasi performa model Support Vector Machine (SVM) dalam skenario penggunaan dunia nyata (real-world scenario). Pada tahap ini, dilakukan simulasi pengujian menggunakan data ulasan baru yang sepenuhnya asing bagi model artinya, data ini tidak pernah terlibat dalam proses pelatihan (training) maupun pengujian (testing) sebelumnya. Simulasi ini bertujuan untuk menguji sejauh mana kemampuan generalisasi model dalam menghadapi variasi bahasa, struktur kalimat, dan ambiguitas sentimen yang sering muncul secara dinamis di kolom ulasan Google Play Store.

Berikut merupakan hasil prediksi model terhadap lima sampel ulasan baru yang dimasukkan secara manual untuk menguji respon sistem:

Tabel 5. 2 Hasil Pengujian Model pada Data Baru

No	Teks Ulasan Baru	Label Sebenarnya	Prediksi Model	Status
1	"Drivernya ramah banget, mobil bersih dan wangi."	Positif	Positif	✓ Benar
2	"Aplikasi error terus pas mau pesen Gofood, tolong diperbaiki."	Negatif	Negatif	✓ Benar
3	"Tarifnya lumayan mahal sekarang dibanding dulu."	Negatif	Negatif	✓ Benar
4	"Biasa aja sih layanannya, standar."	Netral	Netral	✓ Benar
5	"Suka banget sama promonya, tapi sayang server sering down."	Negatif	Positif	✗ Salah

Berdasarkan pengujian terhadap lima sampel data baru tersebut, model SVM berhasil mengklasifikasikan empat data dengan tepat, yang menghasilkan tingkat akurasi simulasi sebesar 80%. Hasil ini menunjukkan bahwa model sangat tangguh dalam mengenali kata-kata yang memiliki polaritas sentimen kuat dan eksplisit, seperti "ramah", "bersih", "error", dan "mahal".

Namun, hasil pengujian pada data kelima memberikan temuan evaluasi yang sangat penting. Pada ulasan "*Suka banget sama promonya, tapi sayang server sering down*", model memberikan prediksi **Positif**, padahal label sebenarnya adalah **Negatif**. Secara teknis, hal ini terjadi karena adanya fenomena *mixed sentiment* (sentimen campuran) dalam satu kalimat. Model SVM dengan pembobotan TF-IDF cenderung memberikan label berdasarkan akumulasi bobot kata yang paling dominan. Dalam kasus ini, frasa "Suka banget" dan "promo" kemungkinan memiliki nilai bobot frekuensi yang lebih tinggi dalam ruang fitur dibandingkan kata "sayang" atau "down", sehingga *hyperplane* mengarahkan ulasan tersebut ke area positif.

BAB VI

KESIMPULAN DAN SARAN

6.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan mengenai analisis sentimen ulasan pengguna aplikasi Grab dan Gojek di Google Play Store menggunakan algoritma Support Vector Machine (SVM), maka dapat ditarik kesimpulan sebagai berikut:

1. Penerapan algoritma Support Vector Machine (SVM) dalam menganalisis sentimen ulasan pengguna aplikasi Grab dan Gojek dapat dilakukan melalui tahapan pengumpulan data, preprocessing teks (case folding, tokenisasi, stopword removal, dan stemming), ekstraksi fitur menggunakan TF-IDF, serta proses pelatihan dan pengujian model. Tahapan tersebut memungkinkan data teks yang tidak terstruktur diubah menjadi representasi numerik sehingga dapat diklasifikasikan ke dalam tiga kategori sentimen, yaitu positif, negatif, dan netral.
2. Tingkat akurasi algoritma Support Vector Machine (SVM) dalam mengklasifikasikan sentimen menunjukkan hasil yang sangat baik. Model SVM menghasilkan akurasi sebesar 91% pada dataset Grab dan 96% pada dataset Gojek. Hasil evaluasi menggunakan confusion matrix juga menunjukkan bahwa sebagian besar data uji berhasil diklasifikasikan dengan benar. Dengan demikian, algoritma SVM terbukti efektif dalam melakukan analisis sentimen terhadap ulasan pengguna aplikasi di Google Play Store.

Berdasarkan hasil tersebut, rumusan masalah dalam penelitian ini telah terjawab dan tujuan penelitian untuk menerapkan serta mengevaluasi kinerja algoritma Support Vector Machine (SVM) dalam analisis sentimen telah tercapai.

6.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, maka saran yang dapat diberikan adalah sebagai berikut:

1. Penelitian selanjutnya disarankan untuk menggunakan jumlah data yang lebih besar serta periode pengambilan data yang lebih panjang agar hasil analisis sentimen dapat menggambarkan persepsi pengguna secara lebih komprehensif.
2. Penelitian berikutnya dapat membandingkan algoritma Support Vector Machine (SVM) dengan metode klasifikasi lain seperti Random Forest, Logistic Regression, atau metode berbasis Deep Learning untuk mengetahui perbedaan performa dan memperoleh hasil klasifikasi yang lebih optimal.
3. Penggunaan teknik representasi teks yang lebih kompleks, seperti word embedding (Word2Vec, FastText, atau BERT), dapat dipertimbangkan untuk meningkatkan pemahaman konteks dan akurasi klasifikasi sentimen.
4. Penelitian selanjutnya dapat mengembangkan analisis ke arah aspect-based sentiment analysis, sehingga tidak hanya mengetahui sentimen secara umum, tetapi juga aspek layanan yang paling sering mendapatkan perhatian pengguna.

DAFTAR PUSTAKA

- Adebayo, T. S., Kartal, M. T., Ağa, M., & Al-Faryan, M. A. S. (2023). Role of country risks and renewable energy consumption on environmental quality: Evidence from MINT countries. *Journal of Environmental Management*, 327, 116884. <https://doi.org/10.1016/j.jenvman.2022.116884>
- Alghifari, D. R., Edi, M., & Firmansyah, L. (2022). Implementasi Bidirectional LSTM untuk Analisis Sentimen Terhadap Layanan Grab Indonesia. *Jurnal Manajemen Informatika (JAMIKA)*, 12(2), 89–99. <https://doi.org/10.34010/jamika.v12i2.7764>
- Amrie, S., Kurniawan, S., Windiatmaja, J. H., & Ruldeviyani, Y. (2022). Analysis of Google Play Store's Sentiment Review on Indonesia's P2P Fintech Platform. *2022 IEEE Delhi Section Conference (DELCON)*, 1–5. <https://doi.org/10.1109/DELCON54057.2022.9753108>
- Asmawati, A., Zahara, C., & Wahjono, S. I. (2025). The Effect of Transformational Leadership on Gojek Organizational Culture on Driver Partner Work Flexibility. *Golden Ratio of Data in Summary*, 5(3), 535–541. <https://doi.org/10.52970/grdis.v5i3.1255>
- Hajarah, H., Suprati, T., & Narasati, R. (2024). IMPLEMENTASI ALGORITMA NAIVE BAYES UNTUK ANALISIS SENTIMEN ULASAN PRODUK MAKANAN DAN MINUMAN DI TOKOPEDIA. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 8(1), 111–118. <https://doi.org/10.36040/jati.v8i1.8237>
- Hidayat, M. R., & Sulistiyono, M. (2022). Comparison of Accuracy and Time Of Naïve Bayes Algorithm with Support Vector Machine Algorithm in Twitter Sentiment Analysis of Peduli Lindungi Application. *2022 5th International Conference on Information and Communications Technology (ICOIACT)*, 172–176. <https://doi.org/10.1109/ICOIACT55506.2022.9972063>
- Lin, C.-H., & Nuha, U. (2023). Sentiment analysis of Indonesian datasets based on a hybrid deep-learning strategy. *Journal of Big Data*, 10(1), 88. <https://doi.org/10.1186/s40537-023-00782-9>
- Mulugeta, A. K., Sharma, D. P., & Mesfin, A. H. (2023). Deep learning for medicinal plant species classification and recognition: a systematic review. In *Frontiers in Plant Science* (Vol. 14). Frontiers Media SA. <https://doi.org/10.3389/fpls.2023.1286088>

- Nurfauzi, O. M., Hilabi, S. S., Nurapriani, F., & Huda, B. (2025). Analisis Sentimen, Grab Indonesi Analisis Sentimen Grab Indonesia Pada Ulasan Google Play Store Menggunakan Algoritma Naïve Bayes Dan SVM. *SMARTICS Journal*, 11(1), 8–13.
<https://doi.org/10.21067/smartics.v11i1.11789>
- Rahardi, M., Aminuddin, A., Abdulloh, F. F., & Nugroho, R. A. (n.d.). Sentiment Analysis of Covid-19 Vaccination using Support Vector Machine in Indonesia. In *IJACSA) International Journal of Advanced Computer Science and Applications* (Vol. 13, Number 6). Retrieved <https://t.co/h5x41UO3tF>
- Samanmali, P. H. C., & Rupasingha, R. A. H. M. (2024). Sentiment analysis on google play store app users' reviews based on deep learning approach. *Multimedia Tools and Applications*, 83(36), 84425–84453.
<https://doi.org/10.1007/s11042-024-19185-w>
- Waspodo, B., Nuryasin, Bany, A. K. N., Kusumaningtyas, R. H., & Rustamaji, E. (2022). Indonesia COVID-19 Online Media News Sentiment Analysis with Lexicon-based Approach and Emotion Detection. *2022 10th International Conference on Cyber and IT Service Management (CITSM)*, 1–6.
<https://doi.org/10.1109/CITSM56380.2022.9935884>
- Wiguna, B. F., Herlawati, H., & Yusuf, A. Y. P. (2023). Sentiment Analysis of On-Demand Ride-Hailing Systems using Support Vector Machine and Naïve Bayes. *PIKSEL : Penelitian Ilmu Komputer Sistem Embedded and Logic*, 11(2), 401–414. <https://doi.org/10.33558/piksel.v11i2.7384>
- Yuniar, P., & Kismiantini. (2023). Analisis Sentimen Ulasan pada Gojek Menggunakan Metode Naïve Bayes. *Statistika*, 23(2), 164–175.
<https://doi.org/10.29313/statistika.v23i2.2353>